ANALITIK RISIKO KETERLAMBATAN PENGIRIMAN PADA RANTAI PASOK MENGGUNAKAN *MACHINE LEARNING* DAN *GRAPH ANALYTICS*

Studi Kasus: DataCo Smart Supply Chain - Assignment II

Nama: Rafael Yudianto

NIM: 2702752495

Kelas: LCD3

Mata Kuliah: COMP8035041 *Big Data Analytics*

PROGRAM STUDI MAGISTER TEKNIK INFORMATIKA

BINUS GRADUATE PROGRAM

DAFTAR ISI

DAFTAR GAMBAR **3**
DAFTAR TABEL **4**
BAB 1. PENDAHULUAN **5**
1.1 Latar Belakang Masalah 5
1.2 Market dan Business Drivers 6
1.3 Pemangku Kepentingan yang Terlibat 6
BAB 2. RANCANGAN SOLUSI BIG DATA **7**
2.1 Metode Pengumpulan Data (Data Ingestion) 7
2.2 Teknologi Penyimpanan Data 7
2.3 Processing Framework 8
2.4 Repositori Kode dan Artefak Implementasi 8
BAB 3. TATA KELOLA IT **10**
3.1 Security 10
3.2 Compliance 10
3.3 Privasi Data 10
3.4 Kualitas Data 10
BAB 4. DATA **12**
4.1 Deskripsi Data 12
4.1.1 Pembersihan Data Transaksi 12
4.1.2 Organisasi Data 14
4.2 Model Data dan Operasi Data 14
4.3 Data Tingkat Pesanan untuk Diolah Menggunakan Machine Learning 15
BAB 5. MACHINE LEARNING **17**
5.1 Data Preprocessing 17
5.2 Feature Engineering 18
5.3 Algoritma 18
5.4 Proses Pengembangan Model dengan dan tanpa Spark MLlib 19
5.5 Evaluasi Model 20
5.6 Analisis 21
BAB 6. GRAPH ANALYTICS **25**
6.1 Pengembangan Graf 25
6.2 Analisis dan Wawasan (Insights) yang Diperoleh 26
BAB 7. VISUALISASI DASHBOARD **30**
7.1 Proses Membangun Dashboard 30
7.2 Interpretasi Bisnis atau Insights yang Diperoleh dari Dashboard 31
DAFTAR PUSTAKA **34**
BINUS UNIVERSITY ARTIFICIAL INTELLIGENCE USE DECLARATION FORM **35**

DAFTAR GAMBAR

Gambar 2.1 Arsitektur dan Alur Pemrosesan DataCo pada Assignment II.....8
Gambar 5.1 Kurva Precision-Recall dan Kurva ROC pada data test: scikit-learn vs Spark MLlib.....21
Gambar 6.1 Subset graf pesanan dan kategori: 210 simpul dan 495 garis penghubung.....27
Gambar 7.1 Antarmuka Utuh Dashboard dan Panel Pemeringkatan Risiko Machine Learning (Top-K Alert).....31
Gambar 7.2 Panel Analisis Topologi Jaringan Kategori Produk dan Kalibrasi Janji Pengiriman (SLA).....32

DAFTAR TABEL

Tabel 1.1 Market dan business drivers....6
Tabel 1.2 Pemangku kepentingan....6
Tabel 2.1 Implementasi dan batas pengujian komponen....7
Tabel 2.2 Rancangan dan implementasi penyimpanan....7
Tabel 3.1 Pemeriksaan kualitas data dan keterbatasannya....11
Tabel 4.1 Sumber data....12
Tabel 4.2 Pemetaan nama kolom....13
Tabel 4.3 Tahapan pembersihan transaksi....13
Tabel 4.4 Organisasi data....14
Tabel 4.5 Peran variabel....15
Tabel 4.6 Model dan operasi data....15
Tabel 4.7 Cakupan data tingkat pesanan Assignment II....16
Tabel 5.1 Fitur dan representasi masukan model....18
Tabel 5.2 Parameter Logistic Regression....18
Tabel 5.3 Pembagian temporal data pesanan....19
Tabel 5.4 Konfigurasi final dua implementasi Logistic Regression....20
Tabel 5.5 Hasil evaluasi pada data test....20
Tabel 5.6 Hasil evaluasi pada data validation....21
Tabel 5.7 Ringkasan pengujian top-k pada data test....22
Tabel 5.8 Distribusi skor peluang: test dan validation pada eksekusi Google Colab....22
Tabel 5.9 Hasil pengujian ablasi kelompok fitur pada data test....23
Tabel 6.1 Definisi graf pesanan dan kategori....25
Tabel 6.2 Jumlah hubungan sepuluh kategori pada graf lengkap....25
Tabel 6.3 Komponen terhubung pada graf lengkap....25
Tabel 6.4 Tingkat keterlambatan per kategori pada graf lengkap....28

BAB 1. PENDAHULUAN

1.1 Latar Belakang Masalah

Dinamika perdagangan elektronik (*e-commerce*) global dan integrasi rantai pasok modern menuntut keandalan pemenuhan pesanan (*order fulfillment*) yang tinggi. Dalam persaingan bisnis yang ketat, kepuasan konsumen (*customer satisfaction*), loyalitas merek, dan retensi pelanggan bergantung pada kepastian serta ketepatan waktu pengiriman barang. Ekspektasi konsumen terhadap transparansi estimasi kedatangan barang dan pelacakan status pesanan secara waktu nyata kini menjadi standar baku operasional logistik modern.

Keterlambatan pengiriman (*late delivery*) menjadi risiko operasional utama dalam manajemen rantai pasok. Ketika pesanan gagal diserahkan tepat waktu, dampak negatif yang timbul mencakup lonjakan beban layanan pelanggan (*customer service*), keluhan konsumen, penalti finansial, serta risiko pelanggan beralih ke penyedia lain. Penelitian empiris manajemen operasi dan rantai pasok menunjukkan bahwa deviasi durasi pemrosesan dan keterlambatan pengiriman berkorelasi langsung dengan penurunan skor ulasan pelanggan serta persepsi kualitas layanan (Akturk et al., 2022).

Tantangan utama industri logistik berskala besar bersumber dari karakteristik data operasional yang tergolong sebagai *Big Data*. Rantai pasok modern memproses puluhan ribu transaksi harian yang mencakup jutaan item barang dan ratusan kategori produk. Transaksi tersebut menjangkau wilayah geografis luas dengan beragam moda pengiriman serta *service-level agreement* (SLA) yang bervariasi. Sebagian besar sistem logistik konvensional mengevaluasi keterlambatan secara reaktif, yaitu mendeteksi masalah setelah jadwal terlewati atau barang telah dibawa kurir. Pendekatan reaktif ini membuat tim operasional tidak sempat mencegah keterlambatan sebelum pesanan dikirimkan.

Peralihan dari mitigasi risiko reaktif menuju manajemen risiko proaktif (*proactive risk management*) memerlukan penerapan kerangka kerja *Big Data Analytics* dan *Machine Learning*. Model prediktif memanfaatkan kombinasi fitur yang tersedia saat pesanan siap diproses, seperti janji durasi pengiriman terjadwal, segmen pasar pelanggan, wilayah pemesanan, dan komposisi keranjang belanja, untuk mengestimasi probabilitas risiko keterlambatan sejak dini. Pendekatan ini memungkinkan tim logistik menyusun daftar prioritas penanganan pesanan (*risk prioritization ranking*) sehingga pesanan berisiko tertinggi memperoleh alokasi sumber daya pemenuhan lebih cepat.

Selain pendekatan pemodelan tabular, pemahaman struktural mengenai pola pembelian bersama memerlukan perspektif relasional berbasis jaringan. *Graph Analytics* memodelkan interaksi antara nomor pesanan dan kategori produk sebagai graf bipartit (*bipartite network*). Melalui pemetaan topologi jaringan ini, analisis sentralitas dan keterhubungan kelompok mengungkap pola kokeanggotaan kategori produk dalam pesanan pelanggan sehingga memperjelas keterkaitan relasional antarkategori yang kerap dipesan bersamaan.

Berdasarkan urgensi bisnis dan kebutuhan analitik tersebut, penelitian ini memanfaatkan dataset DataCo Smart Supply Chain versi 5 (Constante et al., 2019). Dataset ini dipublikasikan secara resmi melalui Mendeley Data dengan lisensi Creative Commons Attribution 4.0 International (CC BY 4.0). Penelitian ini bertujuan merancang, mengimplementasikan, dan mengevaluasi solusi analitik *Big Data* secara terpadu pada lingkungan Google Colab. Cakupan penelitian meliputi pembersihan dan agregasi data transaksi dengan PySpark, pengembangan model *Logistic Regression* menggunakan scikit-learn dan *Spark MLlib*, pelaksanaan studi ablasi fitur empiris, serta eksplorasi topologi graf pesanan-kategori menggunakan *Graph Analytics*.

1.2 *Market* dan *Business Drivers*

Market drivers mencakup ekspektasi pelanggan terhadap estimasi dan pelacakan barang, serta persaingan janji waktu pengiriman. *Business drivers* mencakup beban layanan pelanggan, perencanaan kapasitas gudang, dan pemeliharaan tingkat layanan. Keluaran yang diusulkan berupa daftar prioritas intervensi pesanan dan penataan ulang rak gudang.

Tabel 1.1 *Market* dan *business drivers*

Jenis	Pendorong	Kebutuhan analitik
Market	Ekspektasi estimasi dan pelacakan; persaingan janji pengiriman	Informasi risiko lebih awal untuk membantu pengelolaan ekspektasi
Business	Beban layanan pelanggan dan operasional; kapasitas gudang; tingkat layanan	Daftar prioritas pesanan pada siklus operasional yang dipilih

1.3 Pemangku Kepentingan yang Terlibat

Operations/Logistics merupakan calon pengguna utama skor risiko untuk memprioritaskan pesanan. Koordinator Layanan Pelanggan (*CS Lead*) memanfaatkan estimasi risiko untuk menyiapkan respons sebelum keluhan muncul. Tim Data/TI (*Information Technology*) bertanggung jawab atas keterlacakan data, reproduktibilitas eksperimen, dan penyiapan infrastruktur produksi.

Tabel 1.2 Pemangku kepentingan

Pihak	Informasi	Tindakan
Operations / Logistics	Daftar pesanan dan skor risiko	Meninjau prioritas penanganan
CS Lead	Pesanan berisiko	Mengelola komunikasi dan ekspektasi
Manajemen	Ringkasan wilayah, kategori, moda	Meninjau tingkat layanan
Data/IT	Status *pipeline* dan validasi	Menangani kegagalan pengolahan
Keamanan / privasi	Hak akses dan audit	Mengawasi penggunaan data

BAB 2. RANCANGAN SOLUSI *BIG DATA*

Arsitektur pada Assignment I menempatkan Apache Hadoop sebagai fondasi penyimpanan dan penjadwalan, Apache Spark sebagai pemroses data, serta pustaka pendukung untuk *machine learning* dan analitik jaringan. Pada Assignment II, komponen-komponen tersebut diuji dalam skala bukti konsep (*Proof-of-Concept*) pada Google Colab. HDFS diuji pada sistem berkas (*filesystem*) *runtime* Google Colab, Spark dijalankan secara lokal (*local[2]*), dan komponen analitik dieksekusi dengan Python.

2.1 Metode Pengumpulan Data (*Data Ingestion*)

Ketiga berkas CSV DataCo versi 5 diunduh dari sumber resmi. Data historis ini diimpor dalam bentuk berkas utuh (*batch ingestion*). Pengambilan bertahap atau *streaming* tidak diuji karena sumber data hanya menyediakan berkas statis.

Pengolahan memakai potret historis (*snapshot*), bukan *feed* transaksi operasional waktu nyata (*real-time*). Karakteristik berkas mentah dirangkum pada Tabel 2.1.

Pemeriksaan rekaman klik (*clickstream*) mencakup rentang 1 September 2017 pukul 06.00 hingga 31 Januari 2018 pukul 23.58. Perbedaan rentang ini dibahas pada Bab 4.

Tabel 2.1 Implementasi dan batas pengujian komponen

Fungsi	Implementasi	Belum dilaksanakan
Ingestion	Unduh *snapshot* CSV; verifikasi hash; baca *batch* Python Colab	Pemuatan seluruh CSV ke HDFS; *batch* terjadwal
Storage	HDFS *single-node*; tulis/baca berkas uji	Lapisan *dataset* lengkap; konversi Parquet/JSON
Processing	Pembersihan Python; pembentukan *edge* graf dengan Spark; pelatihan dan evaluasi pada Colab	*Streaming* dan pengukuran *multi-node* belum dilakukan
Analytics/*consumption*	Probabilitas, prediksi, metrik, dan graf tersimpan pada *runtime* Colab	Penggunaan operasional dan intervensi tidak diuji

2.2 Teknologi Penyimpanan Data

Rancangan penyimpanan memisahkan data mentah, data bersih, dan data siap analitik dalam lapisan yang dapat dibaca Spark. HDFS menjadi pilihan penyimpanan pada rancangan tersebut. Dalam implementasi, ketiga lapisan diwakili oleh direktori dan berkas pada *runtime* Google Colab. Pengujian berkas sederhana pada HDFS menunjukkan fungsi tulis dan baca dasar, tetapi *dataset* penelitian tidak dimuat lengkap ke HDFS.

HDFS memakai NameNode untuk mengelola metadata dan DataNode untuk menyimpan blok data. Format penyimpanan menggunakan *comma-separated values* (CSV) untuk transaksi dan *JavaScript Object Notation* (JSON) untuk rencana integrasi rekaman klik (*clickstream*).

Tabel 2.2 Rancangan dan implementasi penyimpanan

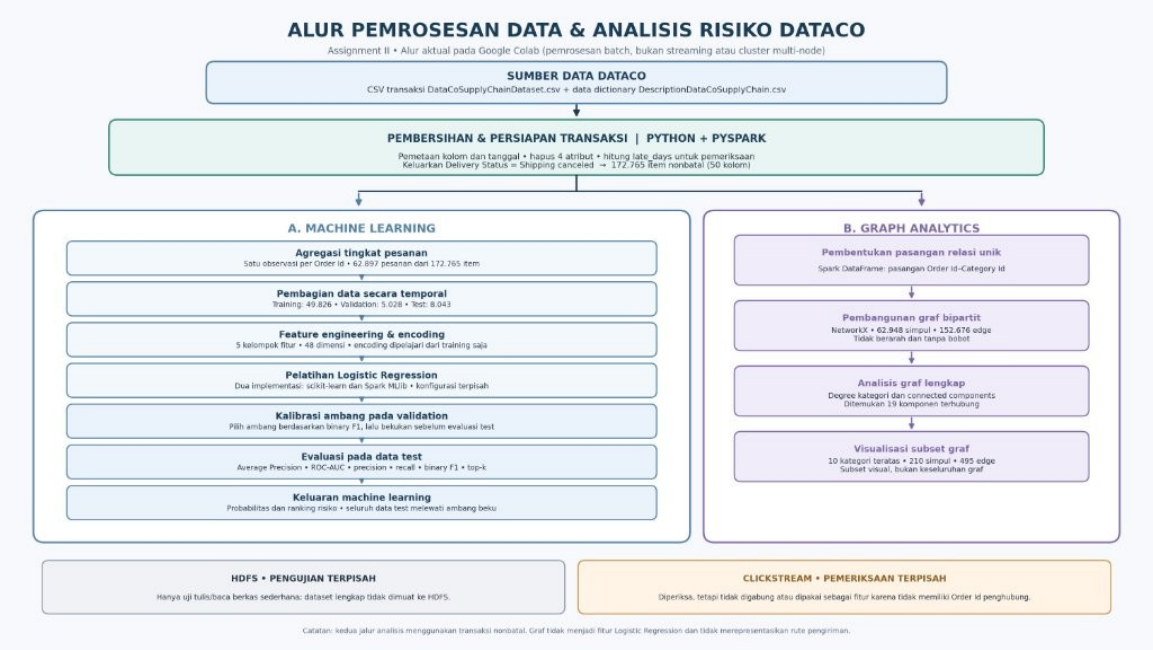
Komponen	Kondisi aktual	Status desain
Apache Hadoop / HDFS	Hadoop 3.4.3; HDFS *single-node*; replication=1	Penyimpanan lapisan data dalam rancangan
CSV mentah/bersih	Berkas pada *runtime* Colab tersedia dan diperiksa	*Dataset* lengkap belum dimuat ke HDFS
Parquet transaksi	Tidak ada konversi terverifikasi	Format target hasil pembersihan
JSON *clickstream*	Sumber aktual masih CSV	Format target; bukan hasil tersedia

2.3 *Processing Framework*

Rancangan arsitektur *Big Data* ini disiapkan untuk pemrosesan terdistribusi (*distributed-ready*) menggunakan abstraksi PySpark DataFrame dan *Spark MLlib Pipeline* API. Dengan demikian, arsitektur ini berpotensi diskalakan ke klaster terdistribusi multi-simpul (*multi-node*), seperti Apache Hadoop YARN atau Kubernetes, tanpa mengubah logika program. Namun, implementasi dieksekusi sebagai bukti konsep (*Proof-of-Concept*, PoC) pada *runtime* tunggal Google Colab berbasis Linux x86_64 dengan Python 3.13, PySpark, dan Java OpenJDK. Apache Spark dijalankan dalam mode *local[2]* (dua *thread* pemrosesan dalam satu VM Google Colab) dengan sistem berkas lokal virtual (file:///), bukan klaster terdistribusi *multi-node*. Pengujian skalabilitas *multi-node* belum dilakukan dan tidak diklaim dalam laporan ini.

Spark mendukung transformasi tabular, agregasi, dan *machine learning* melalui *Spark MLlib*. Pada Colab, Spark dijalankan dalam mode *single-thread* atau *local[2]*. Beban kerja dieksekusi untuk memverifikasi *pipeline*, bukan untuk mengukur skalabilitas atau waktu eksekusi. Tolok ukur kinerja Spark versus scikit-learn tidak dilakukan pada skala produksi. Oleh karena itu, pengujian tidak mencakup uji beban atau keandalan klaster.

Gambar 2.1 merangkum alur aktual dari CSV transaksi pada *runtime* Google Colab.



Gambar 2.1 Arsitektur dan Alur Pemrosesan DataCo pada Assignment II

Alur pengolahan mencakup pemetaan nama kolom, konversi tanggal, penghapusan empat atribut, perhitungan late_days untuk pemeriksaan, dan pemilihan pesanan nonbatal. Data lalu diagregasi menjadi satu observasi per *Order Id*, diubah menjadi fitur, dan dipakai untuk menghasilkan probabilitas serta prediksi. Penerapan daftar prioritas operasional dan pemrosesan *streaming* tidak termasuk pengujian.

2.4 Repositori Kode dan Artefak Implementasi

Untuk mendukung transparansi dan keterlacakan implementasi, kode sumber dan dokumentasi pendukung Assignment II disimpan dalam repositori GitHub. Repositori ini memuat berkas implementasi dan pengujian untuk pengolahan data, *feature engineering*, pengembangan model *Logistic Regression*, evaluasi, serta *Graph Analytics*. Repositori tersebut dapat diakses melalui tautan berikut:

GitHub Repository – COMP8035041 Assignment II DataCo

Repositori ini menjadi referensi pendukung untuk menelusuri implementasi teknis yang dibahas pada Bab 4, Bab 5, dan Bab 6.

BAB 3. TATA KELOLA IT

3.1 Keamanan (*Security*)

Konfigurasi HDFS memakai alamat *loopback* untuk NameNode dan DataNode sehingga komunikasi hanya berjalan di dalam lingkungan Colab. Porta pemrosesan tidak dibuka ke jaringan luar, dan autentikasi Kerberos tidak diaktifkan karena eksperimen berada pada lingkungan terisolasi satu pengguna. Pengamanan data bertumpu pada kontrol akses lingkungan *runtime* Google Colab dan sesi pengguna.

Pembersihan transaksi menghapus *Customer Password* dan *Customer Email* guna mengurangi eksposur kredensial dan risiko keamanan, serta membuang *Product Description* dan *Product Image* yang tidak terpakai.

Dataset DataCo versi 5 dirilis secara publik melalui Mendeley Data dengan lisensi CC BY 4.0 (Constante et al., 2019). Meskipun dapat diakses bebas untuk penelitian akademik, penggunaan *dataset* publik ini tetap menuntut penerapan etika penanganan data akademik secara cermat.

Simulasi insiden, pengujian pemulihan, dan penegakan retensi otomatis belum dilakukan sehingga kesiapan pemulihan bencana tidak diuji. Langkah yang telah dijalankan terbatas pada isolasi lokal serta pemisahan salinan data mentah dari direktori keluaran olahan.

3.2 Kepatuhan (*Compliance*)

DataCo versi 5 dirilis dengan lisensi CC BY 4.0 (Constante et al., 2019) dan DOI 10.17632/8gx2fvg2k6.5. Lisensi ini mengizinkan penggunaan dan pengolahan data untuk keperluan analitik akademik dengan atribusi sumber yang sah. Penilaian kepatuhan pada laporan ini menunjukkan bahwa tata kelola data akademik telah terpenuhi, sedangkan kepatuhan regulasi industri seperti GDPR hanya diposisikan sebagai batas analisis komparatif.

3.3 Privasi Data

General Data Protection Regulation (GDPR, European Parliament and Council of the European Union, 2016) dipakai sebagai rujukan prinsip tata kelola data, bukan penetapan yurisdiksi hukum. Penghapusan empat kolom (*Customer Email*, *Customer Password*, *Product Description*, dan *Product Image*) belum menganonimkan seluruh dataset. Atribut identitas dan lokasi pelanggan masih tersimpan pada data transaksi, sedangkan alamat IP masih tercatat pada berkas rekaman klik (*clickstream*) mentah. Atribut-atribut tersebut memerlukan penilaian privasi tersendiri sehingga dataset ini belum berstatus anonim penuh. Lapisan analitik *clickstream* sendiri tidak dibangun dalam penelitian ini.

3.4 Kualitas Data

Pemeriksaan kualitas mencakup jumlah baris dan kolom, identitas unik, konversi tanggal, duplikasi baris penuh, nilai kosong, serta hubungan label dengan durasi pada cakupan nonbatal. Pemeriksaan kebaruan operasional, perubahan distribusi, rentang seluruh atribut, dan karantina otomatis tidak dilakukan. Nilai late_days negatif menunjukkan durasi aktual lebih pendek daripada jadwal, dan tidak otomatis berarti data salah.

Integritas ketiga CSV diperiksa sebelum eksperimen dengan mencocokkan kondisi berkas terhadap metadata sumber resmi, lalu menyimpan ringkasan nilai hash SHA-256. Pemeriksaan ini memastikan integritas berkas mentah sebelum diproses oleh skrip pembersihan. Pemeriksaan kualitas data disajikan pada Tabel 3.1.

Tabel 3.1 Pemeriksaan kualitas data dan keterbatasannya

Pemeriksaan	Hasil pemeriksaan	Batas
Jumlah, tipe, nilai kosong, ID unik	Diperiksa ulang dari CSV sumber	Pemeriksaan menggunakan Python
Jumlah keluaran bersih	180.519 dan 172.765 baris, masing-masing 50 kolom	Keluaran transaksi, bukan jumlah observasi model
Hash sumber	Metadata resmi tersedia	Ketiga hash cocok dengan sumber resmi
Duplikasi *clickstream*	3.249 baris identik terverifikasi	Identik tidak membuktikan kejadian sama
Makna operasional label	Label konsisten dengan perbandingan durasi	Tidak menetapkan makna penyerahan fisik kepada kurir
Kontrol operasional	Rancangan	Belum diuji

BAB 4. DATA

4.1 Deskripsi Data

Jumlah pada Tabel 4.1 diperoleh dari pembacaan ulang berkas resmi. Ketiga berkas berbentuk CSV (*comma-separated values*), yaitu berkas teks sederhana yang menyusun data dalam baris dan kolom sehingga dapat dibuka oleh program pengolah lembar kerja. Penerbit menyebut data catatan kunjungan situs (*clickstream*) sebagai data tidak terstruktur (*unstructured*), padahal berkas tokenized_access_logs.csv sudah berbentuk tabel dengan delapan kolom tetap. Perbedaan sebutan ini dicatat karena memengaruhi cara pengolahan, sedangkan pilihan format JSON pada rancangan tidak mengubah struktur CSV historis. Tabel 4.1 dibaca per baris: kolom jumlah menyajikan hasil hitung ulang berkas, sedangkan kolom terakhir menjelaskan peran setiap berkas.

Tabel 4.1 Sumber data

Berkas	Baris terverifikasi	Kolom terverifikasi	Fungsi
DataCoSupplyChainDataset.csv	180.519	53	Transaksi tingkat item
tokenized_access_logs.csv	469.977	8	Catatan kunjungan
DescriptionDataCoSupplyChain.csv	52	2	Kamus data

Data sumber memuat 180.519 *Order Item Id* (identitas item barang) dan 65.752 *Order Id* unik (nomor pesanan). Rata-rata jumlah barang per pesanan dihitung pada Persamaan (4.1), sedangkan cakupan nonbatal memuat 62.897 pesanan. Dalam satu *Order Id*, semua barang memiliki tanggal pesanan, tanggal pengiriman, dan status keterlambatan yang sama. Karena itu, keterlambatan cukup dinilai sekali untuk setiap pesanan, tanpa dihitung ulang per barang.

$$\mu = \frac{180.519}{65.752} \approx 2{,}75 \ \ item/pesanan \qquad (4.1)$$

Clickstream memiliki kolom Product, Category, Date, Month, Hour, Department, ip, dan url. Pemeriksaan berkas menunjukkan tidak ada nilai kosong pada kolom-kolom tersebut. *Clickstream* tidak memuat *Order Id* sehingga tautan langsung ke transaksi tidak tersedia tanpa asumsi tambahan mengenai rentang waktu pemesanan.

4.1.1 Pembersihan Data Transaksi

Pembersihan dimulai dari 180.519 baris tingkat barang, dengan satu baris mewakili satu item dalam pesanan. Dari jumlah tersebut, empat kolom yang tidak relevan dan sensitif dihapus, meliputi atribut privasi (*Customer Email* dan *Customer Password*), deskripsi produk yang kosong (*Product Description*), serta tautan gambar (*Product Image*). Penghapusan ini menyisakan 49 kolom transaksi. Selanjutnya, penambahan kolom audit *late_days* menghasilkan berkas dengan 50 kolom. Tahap berikutnya menyaring kohort pengiriman: sebanyak 7.754 baris transaksi dengan *Delivery Status* = *Shipping canceled* dikeluarkan dari cakupan analisis karena pesanan batal tidak melalui pengiriman fisik normal. Jumlah ini terdiri atas 4.062 baris *SUSPECTED_FRAUD* dan 3.692 baris *CANCELED*, yang mencakup 2.855 pesanan unik. Hasil pembersihan menghasilkan 172.765 baris transaksi nonbatal (50 kolom) dengan 62.897 pesanan unik.

Tabel 4.2 Pemetaan nama kolom

Kolom sumber	Nama keluaran	Catatan
order date (DateOrders)	order_date	Tanggal pesanan
shipping date (DateOrders)	shipping_date	Tanggal pengiriman; bukan fitur prediksi
Days for shipping (real)	dispatch_real_days	Alias teknis durasi aktual; definisi mengikuti sumber
Days for shipment (scheduled)	dispatch_scheduled_days	Alias teknis durasi terjadwal; definisi mengikuti sumber
Late_delivery_risk	is_late	Label sumber tidak didefinisikan ulang

Pada data transaksi tidak ditemukan duplikat baris penuh, sedangkan *Product Description* kosong pada seluruh 180.519 baris. Setelah *Customer Email*, *Customer Password*, *Product Description*, dan *Product Image* dihapus, tersisa 49 kolom sumber sebelum penambahan *late_days*.

Kolom *late_days* dihitung sebagai selisih durasi pengiriman aktual dan durasi terjadwal dalam satuan hari, sesuai Persamaan (4.2). Sebagai ilustrasi, barang yang dijadwalkan tiba dalam 3 hari tetapi baru sampai dalam 5 hari memiliki nilai *late_days* sebesar 2 hari. Penambahan kolom ini melengkapi berkas menjadi 50 kolom. Label *is_late* merupakan nama lain dari *Late_delivery_risk* pada data sumber dan definisinya tidak diubah. Pada seluruh item nonbatal, nilai *is_late* konsisten dengan kondisi durasi aktual yang melampaui durasi terjadwal. Kolom *late_days* dibuat murni untuk verifikasi konsistensi tersebut. Nilai *late_days* dan durasi aktual baru terbentuk setelah pengiriman selesai sehingga keduanya tidak dijadikan masukan model.

$$d_{late} = d_{actual} - d_{scheduled} \qquad (4.2)$$

Data transaksi bersih berisi 180.519 baris dan 50 kolom, dengan satu baris mewakili satu barang dalam satu pesanan. Setelah 7.754 item dengan *Delivery Status* = Shipping canceled (dibatalkan) dikeluarkan, data nonbatal memuat 172.765 baris dan 50 kolom. Sebanyak 98.977 item berlabel 1 dan 73.788 berlabel 0. Kolom status akhir hanya dipakai untuk menentukan pesanan mana yang masuk cakupan penelitian dan tidak pernah menjadi masukan model. Karena cakupan ditentukan dari informasi akhir seperti itu, hasil penelitian ini menggambarkan pesanan yang secara historis diketahui tidak dibatalkan. Hasil tersebut belum tentu berlaku sama untuk pesanan baru yang statusnya belum diketahui.

Tabel 4.3 Tahapan pembersihan transaksi

Tahap	Baris terverifikasi	Kolom	Perubahan
Sumber	180.519	53	Empat kolom dihapus: *Customer Email*, *Customer Password*, *Product Description*, Product Image
Penghapusan empat kolom	180.519	49	Empat kolom dihapus
Penambahan late_days	180.519	50	7.754 item Shipping canceled dikeluarkan (4.062 *SUSPECTED_FRAUD* + 3.692 CANCELED)
Cakupan nonbatal	172.765	50	7.754 item batal dikeluarkan

4.1.2 Organisasi Data

Data diorganisasi menjadi tiga lapisan agar jejak pengolahan tetap dapat ditelusuri. Lapisan mentah (*raw*) menyimpan berkas asli dari penerbit tanpa perubahan. Lapisan bersih (*staging*) memuat transaksi yang telah dibersihkan dari atribut sensitif, distandardisasi format tanggalnya, serta dilengkapi kolom audit *late_days*. Lapisan analitik (*analytics*) memuat data tingkat pesanan yang siap dipakai untuk pemodelan *machine learning* dan analisis graf. Pemisahan ini menjaga keterlacakan setiap transformasi dan melindungi berkas mentah dari perubahan tidak sengaja. Struktur data diringkas pada Tabel 4.4.

Tabel 4.4 Organisasi data

Lapisan	Isi	Lokasi/status
Mentah	Tiga CSV dan hash acuan SHA-256	*Runtime* Google Colab; integritas diperiksa
Bersih	Transaksi bersih dan transaksi nonbatal	*Runtime* Google Colab; masing-masing 50 kolom
Siap analitik	Data pesanan, fitur, label, pembagian data, model, dan prediksi	Penyimpanan Google Colab
HDFS	Berkas pengujian sederhana	Uji tulis/baca; bukan penyimpanan *dataset* lengkap

4.2 Model Data dan Operasi Data

Unit observasi, prediksi, dan evaluasi adalah pesanan, dengan *Order Id* sebagai identitas unik. Pada data mentah, satu pesanan dapat terdiri atas beberapa item barang. Untuk menghasilkan satu baris per pesanan, kategori produk diolah menggunakan *multi-hot encoding*, sedangkan *Customer Segment* dan wilayah pasar (*Market*) diambil dari nilai pesanan yang tunggal. Pendekatan ini meniadakan kebutuhan agregasi probabilitas pascaprediksi karena setiap pesanan diprediksi langsung sebagai satu kesatuan.

Rancangan awal pada Assignment I memuat penggabungan skor probabilitas dari tingkat item menjadi tingkat pesanan. Karena data diagregasi ke tingkat pesanan sebelum pemodelan dimulai, penggabungan pascaprediksi tidak lagi diperlukan.

$$R_o = \max_{i \in I_o} r_i \qquad (4.3)$$

Persamaan (4.4) memuat rancangan awal untuk memadukan rekaman klik (*clickstream*) dengan transaksi. Pemaduan tersebut tidak dijalankan karena berkas *clickstream* tidak memiliki identitas pesanan (*Order Id*) yang dapat dipadankan secara langsung.

$$t_{order} - 24\ h \le t_{event} < t_{order} \qquad (4.4)$$

Clickstream tidak disertakan karena kecocokan antara catatan kunjungan dan catatan transaksi belum dapat dipastikan. *Dataset clickstream* berrentang dari September 2017 hingga Januari 2018, sedangkan transaksi mencakup periode 2015 hingga awal 2018. Tidak adanya kunci relasi unik membuat integrasi keduanya berisiko menimbulkan kebocoran informasi buatan.

Tabel 4.5 Peran variabel

Kelompok	Contoh	Peran dan batas
Kandidat informasi sebelum pengiriman	Tepat lima kelompok: jadwal, segmen, *market*, kategori multi-hot, jumlah ID item unik	*Encoding* dipelajari dari *training*; ketersediaan tepat pada waktu operasional belum terbukti
Label	*Late_delivery_risk* / is_late	Target sumber; bukan prediktor dan bukan bukti penyerahan kepada kurir
Informasi hasil akhir	Durasi aktual; *Delivery Status*; shipping_date; late_days	Audit/cakupan; tidak menjadi fitur sebelum pengiriman
Atribut lain dari 50 kolom	Status pesanan, profit, identitas, dan atribut tersisa	Tidak digunakan sebagai fitur; ketersediaan operasional seluruh atribut belum diuji

Durasi aktual, *shipping_date*, *late_days*, *Delivery Status*, dan status pengiriman akhir tidak disertakan dalam fitur model. Atribut-atribut ini baru terbentuk setelah pengiriman selesai sehingga penggunaannya akan menimbulkan kebocoran data (*data leakage*) yang membiaskan hasil evaluasi.

Tabel 4.6 Model dan operasi data

Sumber/keluaran	Unit/model	Operasi	Status
Transaksi	Tabular/item	Pemetaan, tanggal, empat kolom, late_days, nonbatal	Dijalankan menggunakan PySpark/Python Colab
Clickstream	Tabular/kunjungan	Struktur, *timestamp*, kosong, identik penuh	Pemeriksaan selesai; IP tetap pada sumber; deduplikasi tidak diterapkan
Integrasi	Agregat waktu/produk	Jendela 24 jam pra-pesanan	Desain historis Assignment I; tidak dipakai Assignment II
Prioritas	*Order Id*	Model langsung per pesanan	Model langsung per pesanan telah dilatih dan dievaluasi; penggunaan prioritas operasional belum diuji
Aliran masa depan	Kejadian berkelanjutan	Structured *Streaming*	Rancangan; tidak diuji

Seluruh operasi pembersihan data dan pengelompokan transaksi hingga menghasilkan kohort nonbatal 172.765 item dan 62.897 pesanan unik dieksekusi secara terintegrasi pada *runtime* Google Colab langsung dari CSV mentah resmi berukuran 95,9 MB. Dengan demikian, seluruh tahapan pemrosesan data tercatat dan dapat direproduksi secara konsisten dalam lingkungan Google Colab.

Data tingkat pesanan pada bagian 4.3 menjadi dasar pengembangan model pada Bab 5 serta graf pesanan dan kategori pada Bab 6.

4.3 Data Tingkat Pesanan untuk Diolah Menggunakan *Machine Learning*

Data utama penelitian adalah DataCoSupplyChainDataset.csv versi 5, sedangkan berkas DescriptionDataCoSupplyChain.csv yang memuat keterangan arti setiap kolom dipakai untuk memeriksa definisi variabel. Data *clickstream* tidak digunakan dalam model maupun dalam penggabungan fitur. Cakupan penelitian mengecualikan pesanan berstatus *Delivery Status* = Shipping canceled (dibatalkan), dan kolom status itu hanya dipakai untuk memilih serta memeriksa populasi, bukan sebagai prediktor.

Pengelompokan menghasilkan 62.897 pesanan nonbatal dari 172.765 item, setelah 2.855 pesanan yang mencakup 7.754 item dikeluarkan karena memuat barang yang dibatalkan, dan tidak ditemukan pesanan dengan campuran barang batal dan nonbatal. Dari 62.897 pesanan itu, 36.048 berlabel 1 (terlambat) dan 26.849 berlabel 0 (tidak terlambat). Angka inilah yang menjadi jumlah data penelitian, dan jumlahnya mengikuti jumlah pesanan, bukan jumlah barang. Tabel 4.7 merangkum alur angka ini dari transaksi sumber hingga unit model.

Secara konseptual, model diproyeksikan untuk beroperasi pada tahap ketika pesanan telah terkonfirmasi dan siap memasuki proses pengiriman. Namun, dalam penelitian ini, penyaringan kohort dilakukan secara retrospektif menggunakan status akhir pengiriman (*Delivery Status* != Shipping canceled), bukan melalui mekanisme penyaringan pembatalan operasional waktu nyata yang diuji secara langsung. Pemilihan variabel dibatasi pada atribut yang secara logis telah ditentukan sebelum pengiriman berlangsung guna meminimalkan risiko kebocoran target, dengan tetap tunduk pada keterbatasan ketersediaan stempel waktu historis sebagaimana diuraikan pada Bab 5.6.

Tabel 4.7 Cakupan data tingkat pesanan Assignment II

Pemeriksaan	**Hasil**
Transaksi sumber	180.519 item; 65.752 pesanan
Cakupan dipertahankan	172.765 item; 62.897 pesanan
Dikeluarkan	7.754 item; 2.855 pesanan
Pesanan campuran batal/nonbatal	0
Target tingkat pesanan	0 = 26.849; 1 = 36.048
Unit model	Satu observasi per *Order Id*; 48 dimensi aktual

BAB 5. *MACHINE LEARNING*

5.1 *Data Preprocessing*

Prapengolahan (*preprocessing*) mengubah data mentah menjadi bentuk yang dapat diolah model. Tahap ini mencakup pemilihan kohort pesanan yang valid, transformasi fitur kategorikal dan numerik, serta penyusunan matriks masukan terstandarisasi untuk proses pelatihan model.

Integritas ketiga CSV pada eksperimen diperiksa. Data sumber memuat 180.519 item dalam 65.752 pesanan. Pada cakupan yang dipertahankan, tidak ditemukan konflik target, konflik atribut bernilai tunggal dalam pesanan, maupun kategori kosong. Temuan ini penting karena penggabungan data per pesanan mengandaikan setiap pesanan hanya memiliki satu nilai untuk target dan untuk atribut seperti jadwal, segmen, dan *market*.

Model matematika mengolah bilangan numerik sehingga setiap kategori produk diubah menjadi kolom biner (*one-hot* atau *multi-hot encoding*). Representasi biner ini memungkinkan variabel kategorikal diproses oleh algoritma regresi tanpa memunculkan asumsi urutan ordinal.

Karena satu pesanan dapat memuat beberapa kategori produk, representasi kategori disusun melalui pengkodean multikategori (*multi-hot encoding*). Jika sebuah pesanan memuat kategori 17 dan 24, kedua kolom tersebut bernilai 1, sedangkan kolom kategori lainnya bernilai 0.

Dua fitur numerik dipertahankan dalam satuan asli tanpa penskalaan maupun transformasi logaritmik. Nilai numerik atau identitas wajib yang kosong atau bernilai takhingga memicu penghentian pemrosesan tanpa imputasi tebakan. Seluruh aturan transformasi yang dipelajari dari data latih (*training set*) diterapkan secara konsisten pada data validasi (*validation set*) dan data uji (*test set*) tanpa pembelajaran ulang guna mencegah kebocoran data (*data leakage*).

Penanda biner *MISSING* tidak pernah aktif pada kohort nonbatal karena seluruh transaksi memiliki identitas *Category Id* yang lengkap. Sebaliknya, penanda khusus *UNKNOWN* aktif pada 99,1% pesanan data uji karena memuat kategori baru yang tidak ditemui pada data latih. Karena koefisien *UNKNOWN* bernilai nol, model tidak mempelajari pengaruh kategori baru secara langsung, melainkan mengandalkan kontribusi fitur nonkategori seperti jadwal pengiriman dan segmen pelanggan. Sebagai strategi mitigasi lanjutan, teknik *OTHER* dapat diterapkan untuk menggabungkan kategori berfrekuensi rendah berdasarkan distribusi pada data latih, bukan dari informasi data uji.

Rincian kuantitatif menunjukkan bahwa 19 kategori baru tersebut adalah *Category Id* 4 dan 59 sampai 76. Pada data uji (*test set*), sebanyak 7.972 dari 8.043 pesanan (99,12%) memuat paling sedikit satu kategori baru, dan 7.964 di antaranya hanya memuat kategori baru. Sebagai pembanding, pada data validasi (*validation set*) proporsinya hanya 54 pesanan (1,07%), sedangkan pada data latih (*training set*) kategori baru sama sekali tidak ditemukan (0 pesanan atau 0%). Skor rata-rata pesanan uji yang memuat kategori baru adalah 0,5731 dengan tingkat keterlambatan 0,5773, sedangkan 71 pesanan tanpa kategori baru memiliki skor rata-rata 0,5247 dan tingkat keterlambatan 0,4789. Karena koefisien *UNKNOWN* bernilai nol, selisih skor tersebut berasal dari fitur lain, bukan dari kategori baru. Teknik *OTHER* sebagai pengembangan lanjutan harus dibentuk dari aturan data latih, bukan dari informasi data uji.

5.2 *Feature Engineering*

Model menggunakan lima kelompok fitur masukan. Kelompok tersebut mencakup jadwal pengiriman yang dijanjikan (*Days for shipment (scheduled)*), segmen pelanggan (*Customer Segment*), wilayah pasar (*Market*), komposisi kategori produk (*Category Id* dengan *multi-hot encoding*), serta jumlah *Order Item Id* unik per pesanan. Jadwal pengiriman merepresentasikan komitmen waktu, segmen pelanggan dan pasar mencerminkan konteks pengiriman, kategori menggambarkan jenis produk, dan jumlah item mengukur kompleksitas pesanan. Seluruh fitur dibentuk dari data transaksi nonbatal yang sah tersedia sebelum pengiriman dilakukan.

Jumlah item menghitung baris item pesanan unik (*unique order line items*), bukan jumlah SKU (nomor identitas jenis barang)/jenis produk maupun total kuantitas barang. Dengan demikian, produk yang sama pada dua baris item berbeda tetap dihitung sebagai dua entri. Quantity, atribut keuangan, dan variabel turunannya tidak digunakan dalam model.

Atribut *Days for shipping (real)*, *dispatch_real_days*, *shipping_date*, *late_days*, *Delivery Status*, dan status akhir pengiriman tidak disertakan dalam model. Variabel-variabel tersebut baru terbentuk pascapengiriman sehingga penyertaannya akan memicu kebocoran target (*target leakage*) yang membuat evaluasi performa model tidak valid.

Tabel 5.1 Fitur dan representasi masukan model

Komponen	Representasi yang digunakan
Unit dan target	*Order Id*; *Late_delivery_risk*
Lima kelompok fitur	Jadwal; segmen; *market*; *Category Id* multi-hot; jumlah *Order Item Id* unik
Quantity dan keuangan	Tidak diaktifkan, termasuk turunannya
Statistik transformasi	*Vocabulary* hanya *fit* pada *training*; *MISSING* dan *UNKNOWN*
Matriks input final	49.826 × 48; 5.028 × 48; 8.043 × 48; tanpa *scaling*/log

Encoding menghasilkan 48 kolom masukan, yang dalam laporan ini disebut juga 48 dimensi: 2 kolom angka, 5 kolom *Customer Segment*, 7 kolom *Market*, dan 34 kolom *Category Id*. Kolom kategori itu sudah mencakup kedua penanda khusus (*MISSING* dan *UNKNOWN*), sebagaimana dijelaskan pada bagian 5.1. Matriks *training* berukuran 49.826 baris pesanan × 48 kolom, *validation* 5.028 × 48, dan *test* 8.043 × 48. Tabel 5.1 merangkum susunan masukan ini dan dibaca sebagai daftar komponen, bukan sebagai hasil evaluasi.

5.3 Algoritma

Penelitian menerapkan regresi logistik (*Logistic Regression*), yaitu model linier yang mengestimasi peluang keterlambatan pesanan. Keluarannya berupa nilai probabilitas kontinu yang dapat diurutkan. Eksperimen diimplementasikan pada dua pustaka berbeda, scikit-learn (Pedregosa et al., 2011) dan *Spark MLlib* (Meng et al., 2016), dengan parameter tetap pada Tabel 5.2. Kedua implementasi menerapkan regularisasi L2 tanpa pembobotan kelas, penyeimbangan data ulang (*resampling*), atau penalaan hiperparameter otomatis. Parameter random_state=42 dicatat dalam konfigurasi scikit-learn, tetapi tidak memengaruhi optimasi karena *solver lbfgs* bersifat deterministik.

Reproduktibilitas eksperimen didukung melalui pencatatan versi perangkat lunak, konfigurasi model, data, dan kode pengolahan. *Baseline* adalah pembanding paling sederhana: model ini tidak melihat data pesanan sama sekali, melainkan menebak memakai proporsi kelas positif pada data *training* sebagai probabilitas konstan.

Tabel 5.2 Parameter *Logistic Regression*

Implementasi	Parameter
scikit-learn	C=1,0; *solver=lbfgs*; max_iter=1000; tol=0,000001; random_state=42 (tidak berpengaruh pada *lbfgs*); class_weight=None

Implementasi	Parameter
Spark MLlib	regParam=0,1; elasticNetParam=0,0; maxIter=1000; tol=0,000001; standardization=False
Hubungan parameter	Tidak dinyatakan ekuivalen; dibandingkan sebagai konfigurasi primer terpisah
Model tambahan	*Random Forest* dan *Gradient Boosting* bersifat eksploratori dan dikeluarkan dari run final
Refit	Tidak melatih ulang menggunakan gabungan *training* dan *validation*

Parameter diterapkan tanpa penalaan hiperparameter otomatis (*hyperparameter tuning*). Implementasi scikit-learn menggunakan regularisasi C=1,0, sedangkan *Spark MLlib* menggunakan regParam=0,1. Perbedaan formulasi fungsi objektif antara kedua pustaka dicatat sebagai karakteristik teknis masing-masing kerangka kerja.

5.4 Proses Pengembangan Model dengan dan tanpa *Spark MLlib*

Data dibagi menurut urutan temporal tanggal pesanan (*order_date*), bukan secara acak. Data latih (*training*) mencakup transaksi sebelum 1 Juli 2017, data validasi (*validation*) berlangsung dari 1 Juli hingga 30 September 2017, dan data uji (*test*) mencakup rentang 1 Oktober 2017 hingga 31 Januari 2018. Pembagian berbasis waktu ini mencerminkan skenario operasional nyata, saat model dilatih pada data historis dan diuji pada periode masa depan.

Setiap *Order Id* hanya berada dalam satu bagian sehingga satu pesanan tidak muncul di dua bagian sekaligus. Hal ini menjamin tidak ada kebocoran observasi antar-subset data.

Tabel 5.3 Pembagian temporal data pesanan

Bagian	Label 0	Label 1	Jumlah
Training	21.302	28.524	49.826
Validation	2.140	2.888	5.028
Test	3.407	4.636	8.043

Tabel 5.3 menunjukkan jumlah dan distribusi label pada setiap bagian data. Setiap observasi memiliki *Order Id* unik. Kedua implementasi menerima susunan fitur yang sama, dan probabilitas dari Spark dicocokkan kembali menggunakan *Order Id*. Model dilatih murni pada data latih, tanpa pelatihan ulang menggunakan gabungan data latih dan validasi.

Eksperimen final dijalankan pada Google Colab dengan Python 3.13.16, Linux x86_64, dan Spark 4.0.4. Spark dijalankan dengan pengaturan *master local[2]*, yaitu komputasi menggunakan dua *thread* pemrosesan lokal dalam satu proses mesin virtual. Penyimpanan menggunakan sistem berkas lokal (*filesystem*) Colab, bukan klaster HDFS terdistribusi. Konfigurasi ini mendokumentasikan spesifikasi eksekusi bukti konsep, bukan pembuktian skalabilitas *multi-node* industri.

Seluruh angka yang dilaporkan pada Bab 5 diambil dari eksekusi final pada Google Colab ini. Pemeriksaan keterlacakan dan reproduktibilitas dilakukan dengan memverifikasi berkas metrik keluaran JSON dan larik probabilitas yang dihasilkan langsung dari *pipeline* Colab.

Eksekusi final menghasilkan model, probabilitas, prediksi, ambang *validation*, metrik, dan statistik graf. Data utama berukuran 95.910.149 byte (sekitar 91,5 MiB). Seluruh pelatihan, eksekusi Spark, dan komputasi graf dilakukan pada *runtime* Google Colab. Pengukuran waktu eksekusi dan uji skalabilitas *multi-node* tidak dilakukan pada eksperimen ini. Berkas pendukung eksperimen tersimpan bersama laporan ini, meliputi skrip pengolahan, keluaran JSON metrik, berkas prediksi per model, dan daftar checksum berkas pada SHA256SUMS.txt di direktori analisis-lanjutan/.

Tabel 5.4 menegaskan bahwa konfigurasi scikit-learn C=1,0 dan Spark regParam=0,1 merupakan dua spesifikasi final yang terpisah. Hasil kedua pustaka dibandingkan pada partisi data dan representasi fitur yang identik, tanpa klaim kesetaraan parameter teoretis.

Tabel 5.4 Konfigurasi final dua implementasi *Logistic Regression*

Implementasi	Konfigurasi final	Status perbandingan	Batas klaim
scikit-learn	C=1,0	Primer	Tidak ekuivalen dengan regParam Spark
Spark MLlib	regParam=0,1	Primer	Hasil dibandingkan secara deskriptif

Perbedaan kecil pada *Average Precision* (AP), kualitas pemeringkatan risiko, dan *ROC-AUC* dibaca sebagai hasil deskriptif dari dua implementasi dengan formulasi regularisasi berbeda. Tidak ada uji inferensial untuk menyatakan salah satu pustaka lebih unggul.

5.5 Evaluasi Model

Metrik evaluasi menentukan efektivitas prioritas penanganan pesanan bagi tim operasional. Empat indikator dasar dihitung dari matriks konfusi pada ambang keputusan tertentu. Positif benar (*True positive*, TP) menandai pesanan yang terbukti terlambat dan berhasil diprediksi berisiko. Positif semu (*False positive*, FP) mencakup pesanan tepat waktu yang keliru ditandai berisiko. Negatif semu (*False negative*, FN) adalah pesanan terlambat yang gagal dideteksi model. Negatif benar (*True negative*, TN) mencakup pesanan tepat waktu yang diprediksi aman.

Berdasarkan hitungan tersebut, presisi (*precision*) didefinisikan sebagai TP/(TP+FP), yaitu proporsi prediksi berisiko yang benar-benar terlambat. Daya ingat (*recall*) adalah TP/(TP+FN), yaitu proporsi seluruh pesanan terlambat yang berhasil dijaring model. *Binary F1* merupakan rata-rata harmonik 2TP/(2TP+FP+FN) untuk kelas 1 yang merefleksikan keseimbangan presisi dan *recall*. Matriks konfusi (*confusion matrix*) menyajikan tabel silang evaluasi berurutan: TN, FP, FN, dan TP. Untuk mengantisipasi pembagian dengan nol, evaluasi menetapkan parameter zero_division=0.

Dua metrik lain mengevaluasi kualitas urutan peringkat tanpa terikat pada satu ambang batas kaku. Presisi rata-rata (*Average Precision*, AP), yang dihitung melalui average_precision_score, menjadi metrik evaluasi primer untuk pemeringkatan pesanan terlambat (label 1). AP merangkum kurva presisi dengan bobot kenaikan *recall*. Semakin tinggi AP, semakin akurat model menempatkan pesanan terlambat pada urutan teratas antrean risiko. Evaluasi juga menyajikan area di bawah kurva karakteristik operasi penerima (*Area Under the Receiver Operating Characteristic Curve*, *ROC-AUC*) untuk mengukur kemampuan diskriminasi global antara kelas terlambat dan tepat waktu.

Ambang klasifikasi adalah angka batas peluang: pesanan berpeluang sama atau lebih tinggi daripada batas tersebut dikelompokkan sebagai kelas 1 (berisiko terlambat), sedangkan pesanan di bawah batas dikelompokkan sebagai kelas 0 (tidak berisiko terlambat).

Tabel 5.5 Hasil evaluasi pada data *test*

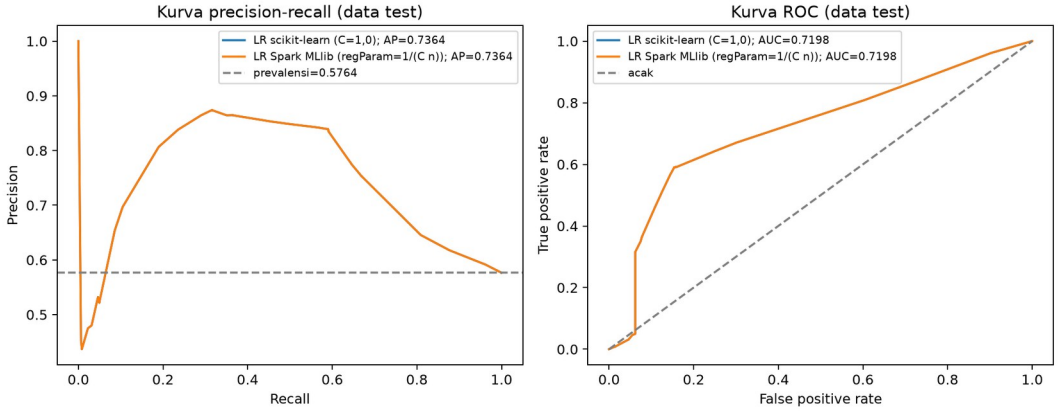
Ukuran	***Baseline***	**LR scikit-learn**	**LR *Spark MLlib***
Average precision	0,576402	0,736424	0,736851
ROC-AUC	0,500000	0,719782	0,720601
Precision kelas 1	0,576402	0,576402	0,576402
Recall kelas 1	1,000000	1,000000	1,000000
Binary F1	0,731288	0,731288	0,731288
Confusion matrix (TN, FP, FN, TP)	TN=0, FP=3.407 FN=0, TP=4.636	TN=0, FP=3.407 FN=0, TP=4.636	TN=0, FP=3.407 FN=0, TP=4.636
Threshold *validation*	0,572472	0,307694	0,446602

Tabel 5.5 dan Tabel 5.6 menyajikan hasil evaluasi pada data uji (*test*) dan validasi (*validation*), dengan setiap kolom merepresentasikan satu model dan setiap baris merepresentasikan metrik evaluasi.

Tabel 5.6 Hasil evaluasi pada data *validation*

Ukuran	*Baseline*	LR scikit-learn	LR *Spark MLlib*
Average precision	0,574383	0,744407	0,744407
ROC-AUC	0,500000	0,719207	0,719909
Precision kelas 1	0,574383	0,574383	0,574612
Recall kelas 1	1,000000	1,000000	1,000000
Binary F1	0,729661	0,729661	0,729846
Confusion matrix (TN, FP, FN, TP)	TN=0, FP=2.140 FN=0, TP=2.888	TN=0, FP=2.140 FN=0, TP=2.888	TN=2, FP=2.138 FN=0, TP=2.888
Threshold validation	0,572472	0,307694	0,446602

Gambar 5.1 menyajikan kurva *Precision-Recall* dan ROC pada data uji untuk scikit-learn dan *Spark MLlib*. Kurva ini memperlihatkan bahwa kedua implementasi mempertahankan presisi tinggi pada persentil ambang atas, menunjukkan konsistensi performa pemeringkatan risiko lintas pustaka.



Gambar 5.1 Kurva *Precision-Recall* dan Kurva ROC pada data *test*: scikit-learn vs *Spark MLlib*

5.6 Analisis

Pada data *test*, AP *baseline* adalah 0,576402. *Logistic Regression* scikit-learn menghasilkan AP 0,736424, sedangkan *Spark MLlib* menghasilkan AP 0,736851. Peningkatan AP sebesar +0,16 di atas *baseline* menunjukkan kemampuan pemeringkatan risiko yang konsisten antara kedua pustaka pada data uji.

Pada ambang *validation*, seluruh 8.043 pesanan *test* diprediksi sebagai kelas 1 (berisiko terlambat) oleh *baseline* dan kedua implementasi. Hasil *confusion matrix* pada data *test* mencatat TN=0 (tidak ada pesanan tepat waktu yang dikenali benar), FP=3.407 (pesanan tepat waktu ikut ditandai berisiko), FN=0 (tidak ada keterlambatan yang terlewat), dan TP=4.636. *Precision* mencapai 0,576402, *recall* 1,000000, dan *binary F1* 0,731288. Secara praktis, seluruh keterlambatan tertangkap, tetapi 3.407 peringatan palsu menambah beban verifikasi bagi tim operasional.

Pada *validation*, Spark masih mengklasifikasikan dua observasi negatif dengan benar, tetapi aturan ambangnya tetap hampir seluruhnya positif, jadi model belum bisa menolak pesanan yang aman secara luas. Karena itu, model menunjukkan kapasitas untuk diuji sebagai alat pemeringkatan prioritas risiko, bukan untuk memutuskan ya atau tidak secara otomatis.

Hasil pengujian *top-k* menunjukkan presisi yang kuat pada kelompok prioritas. Angka ini dihitung dari skor peluang *Logistic Regression* scikit-learn (konfigurasi pada Tabel 5.2). Spark MLlib menghasilkan pola yang hampir sama, yaitu 1.088 pesanan dengan *precision* 0,8061, 1.671 pesanan dengan *precision* 0,8737, dan 2.488 pesanan dengan *precision* 0,8533 pada batas persentil yang sama.

Pada batas persentil 10% dengan seluruh *ties* disertakan, terpilih 1.091 pesanan atau 13,56% dari 8.043 pesanan *test* (3,56 poin persentase di atas target 10%), dengan TP=880 dan *precision* 0,8066. Pada batas persentil 20% terpilih 1.674 pesanan atau 20,81% (TP=1.463, *precision* 0,8740), dan pada batas persentil 30% terpilih 2.496 pesanan atau 31,03% (TP=2.128, *precision* 0,8526). Ketiganya menghasilkan *lift*, yaitu *precision* dibagi prevalensi kelas pada data *test* (0,5764): 1,40 pada batas 10%, 1,52 pada batas 20%, dan 1,48 pada batas 30%.

Selisih cakupan aktual terjadi karena *ties*, yaitu beberapa pesanan memiliki skor yang sama pada batas persentil. Karena semua pesanan dengan skor batas itu ikut disertakan, jumlah terpilih tidak terpotong tepat pada 10%, 20%, atau 30% dari 8.043 pesanan. Sebagai gambaran praktis, *precision* 0,8740 berarti sekitar 87 dari setiap 100 pesanan yang masuk kelompok 20% teratas benar-benar terlambat pada data *test*. Nilai *baseline* 0,5764 identik dengan proporsi kelas positif (*late delivery*) pada data *test*, yaitu 4.636 dari 8.043 pesanan.

Tabel 5.7 Ringkasan pengujian *top-k* pada data *test*

Cutoff	**Implementasi**	**Pesanan terpilih**	**Cakupan aktual**	***True positive***	***Precision***	***Lift***
10%	scikit-learn	1.091	13,56%	880	0,8066	1,40
10%	*Spark MLlib*	1.088	13,53%	877	0,8061	1,40
20%	scikit-learn	1.674	20,81%	1.463	0,8740	1,52
20%	*Spark MLlib*	1.671	20,78%	1.460	0,8737	1,52
30%	scikit-learn	2.496	31,03%	2.128	0,8526	1,48
30%	*Spark MLlib*	2.488	30,93%	2.123	0,8533	1,48

Kedua implementasi meningkatkan kemampuan pemeringkatan risiko dibandingkan *baseline*. Pada data *test*, *Average Precision* mencapai sekitar 0,736, jauh melampaui prior kelas mayoritas (0,576). Capaian ini mengonfirmasi keandalan model sebagai instrumen pemeringkat prioritas operasional.

Penggunaan ambang beku menyebabkan seluruh pesanan uji terklasifikasi positif pada ambang 0,307694 (scikit-learn) dan 0,446602 (Spark) sehingga model tidak dapat difungsikan sebagai pengambil keputusan biner tunggal tanpa penyesuaian ambang operasional.

Penyebab seluruh 8.043 pesanan *test* berada di atas ambang perlu dijelaskan secara transparan. Ambang yang dioptimalkan pada *validation* menghasilkan angka ambang yang relatif rendah (0,307694 untuk scikit-learn dan 0,446602 untuk *Spark MLlib*). Akibatnya, seluruh distribusi skor pada data *test* berada di atas batas ambang tersebut.

Mekanisme ambang *validation* yang memaksimalkan *binary F1* pada data *validation* menghasilkan angka ambang yang berada di bawah nilai probabilitas prediksi terendah pada data *test*. Dengan demikian, hasil semua-positif pada data *test* merupakan konsekuensi mekanis dari pembekuan ambang *validation*, bukan kesalahan kalkulasi. Hasil ini menegaskan bahwa model belum efektif sebagai pemutus biner otomatis. Namun, model terbukti andal dalam menyusun urutan prioritas risiko bagi tim operasional logistik.

Tabel 5.8 Distribusi skor peluang: *test dan validation pada eksekusi Google Colab*

Lingkungan	**Implementasi dan Data**	**n**	**Minimum**	**Median**	**Maksimum**	**Skor ≥ ambang**
Colab	scikit-learn, *test*	8.043	0,353144	0,420483	0,914649	8.043 (100,00%)
Colab	*Spark MLlib, test*	8.043	0,447808	0,453735	0,865002	8.043 (100,00%)
Colab	scikit-learn, *validation*	5.028	0,307694	0,426947	0,935811	5.028 (100,00%)
Colab	*Spark MLlib, validation*	5.028	0,446311	0,453239	0,865781	5.026 (99,96%)

Tabel 5.8 menyajikan ringkasan distribusi statistik skor peluang hasil prediksi model pada data uji dan validasi.

Nilai minimum dan maksimum menunjukkan rentang skor prediksi yang berbeda pada tiap implementasi, dengan median berkisar antara 0,42 dan 0,45. Median tersebut berada di bawah prevalensi positif data uji (0,5764). Perbandingan median dan prevalensi ini belum memastikan kalibrasi probabilitas absolut model. Oleh karena itu, skor probabilitas dipakai murni untuk mengevaluasi pemeringkatan risiko, bukan sebagai probabilitas keterlambatan individual yang pasti. Bagi tim operasional, skor ditujukan untuk menyusun urutan penanganan pesanan. Pengujian kalibrasi mendalam, seperti *calibration curve* dan *Brier score*, dapat dieksplorasi pada penelitian berikutnya.

Seluruh nilai *Average Precision*, *ROC-AUC*, presisi, *recall*, *binary F1*, dan matriks konfusi pada Bab 5 telah diverifikasi silang terhadap berkas keluaran Colab (evidence-colab-final-2026-10-22.json) dan daftar *hash* SHA256SUMS.txt. Verifikasi ini memastikan seluruh metrik evaluasi dapat dipertanggungjawabkan dan direproduksi secara konsisten.

Model final dibatasi pada *Logistic Regression*. *Random Forest* (Breiman, 2001) dan *Gradient Boosting* (Friedman, 2001), uji tanpa sebagian fitur (*ablation*), serta variasi representasi jadwal pernah dieksplorasi. Ketiganya tidak menjadi bagian dari uji utama (run konfirmatori) dan tidak dipakai untuk memilih model utama.

Tabel 5.9 Hasil pengujian ablasi kelompok fitur pada data *test*

Kelompok Fitur	**Jumlah Fitur**	**AP *Test***	**ROC-AUC *Test***	**Interpretasi Kontribusi**
Semua fitur (model penuh)	48	0,7364	0,7198	Model terintegrasi (jadwal, pesanan, kategori, pasar, segmen)
Jadwal saja	1	0,7249	0,7159	Fitur *Days for shipment (scheduled)* menyumbang daya prediktif utama
Jadwal + jumlah item	2	0,7255	0,7164	Penambahan jumlah item memberikan sedikit peningkatan AP (+0,0006)
Tanpa jadwal	47	0,5836	0,5073	Ketiadaan fitur jadwal menyebabkan penurunan tajam AP (-0,1528)
Segmen + *market* saja	12	0,5818	0,5078	Sinyal kontekstual pasar dan segmen pelanggan
Kategori saja	34	0,5766	0,5000	Sinyal kategori marginal, mendekati garis dasar *baseline*
Baseline (prior)	0	0,5764	0,5000	Ambang frekuensi dasar proporsi kelas mayoritas

Hasil studi ablasi pada Tabel 5.9 menunjukkan bahwa daya pembeda model *Logistic Regression* didominasi oleh fitur jadwal pengiriman (*Days for shipment (scheduled)*). Secara mandiri, fitur ini menghasilkan *Average Precision* 0,7249 (*ROC-AUC* 0,7159). Fitur ini merupakan durasi terjadwal yang diketahui sebelum pengiriman berlangsung sehingga terbebas dari kebocoran target (*target leakage*). Sebaliknya, penghapusan fitur jadwal menyebabkan AP merosot ke 0,5836, mendekati *baseline* tanpa fitur (0,5764). Bukti empiris ini menjelaskan mengapa performa pemeringkatan model tetap stabil meski 7.972 dari 8.043 pesanan uji (99,12%) memuat kategori produk baru di luar data latih. Fitur kategori produk hanya menyumbang AP marjinal sebesar 0,5766 (*ROC-AUC* 0,5000) sehingga keandalan pemeringkatan risiko bertumpu pada variabel jadwal pengiriman.

Ketersediaan fitur saat inferensi tidak dapat direkonstruksi sepenuhnya dari data historis. Empat kelompok fitur (jadwal, segmen pelanggan, pasar, dan kategori) tidak memiliki riwayat perubahan status, sedangkan jumlah item pesanan mengandaikan seluruh transaksi telah tercatat lengkap. Oleh karena itu, temuan penelitian ini merefleksikan evaluasi retrospektif data historis, bukan klaim kesiapan produksi langsung.

Kesimpulan ini juga terbatas karena tiga hal. Pertama, data dibatasi pada pesanan yang secara historis tidak dibatalkan. Kedua, urutan waktu memakai order_date sebagai perkiraan. Ketiga, kematangan label tidak diketahui, artinya tim peneliti tidak tahu kapan status setiap pesanan benar-benar final. *Dataset* tidak memuat kolom waktu yang mencatat saat status akhir ditetapkan, sedangkan pengiriman sendiri berlangsung setelah tanggal pesanan. Metrik hanya berlaku kondisional untuk pesanan yang secara retrospektif diketahui tidak dibatalkan. Pengujian untuk penggunaan nyata memerlukan definisi kapan prediksi dilakukan, rekonstruksi nilai fitur pada saat itu, pencatatan waktu ketersediaan label, dan pengujian ke depan yang terpisah.

BAB 6. *GRAPH ANALYTICS*

6.1 Pengembangan Graf

Graf pesanan-kategori dimodelkan sebagai graf bipartit tak berarah. Himpunan simpul (*node*) terdiri atas nomor pesanan (*Order Id*) dan kategori produk (*Category Id*). Garis penghubung (*edge*) menghubungkan simpul pesanan dengan simpul kategori jika pesanan memuat minimal satu item dari kategori tersebut. Graf tidak memuat sisi antarsesama pesanan maupun antarsesama kategori, serta bebas dari sisi ganda dan gelang diri (*self-loop*). Karakteristik graf dirangkum pada Tabel 6.1.

Graf lengkap memuat 62.948 simpul (62.897 pesanan dan 51 kategori) serta 152.676 garis penghubung pada seluruh dataset nonbatal.

Tabel 6.1 Definisi graf pesanan dan kategori

Komponen	Definisi
Node pesanan	Satu *Order Id* yang dipertahankan pada kohort nonbatal
Node kategori	Satu *Category Id* yang muncul pada pesanan tersebut
Edge bipartit	Pasangan unik pesanan–kategori tanpa bobot dan tanpa arah
Metrik final	*Degree* kategori dan *connected components*

Visualisasi subset graf dibuat dengan algoritma tata letak pegas (*spring layout*) menggunakan parameter seed=42 dan iterations=50 untuk menjamin reproduktibilitas posisi simpul.

Nilai tambah analitik graf bipartit terletak pada pemetaan topologi jaringan. Graf mengidentifikasi 19 komponen terhubung, didominasi satu komponen raksasa (*giant component*) berisi 54.966 simpul (54.933 pesanan dan 33 kategori) dengan 144.712 garis penghubung. Pasangan relasi unik pesanan-kategori diekstraksi melalui operasi Spark DataFrame pada *runtime* Google Colab. Pembentukan graf dan perhitungan metrik (*degree*, komponen terhubung) dieksekusi menggunakan pustaka NetworkX dalam memori mesin tunggal, bukan kerangka kerja terdistribusi seperti GraphX.

Tabel 6.2 Jumlah hubungan sepuluh kategori pada graf lengkap

Category Id	***Degree* (pesanan unik)**
17 (Cleats)	19.534
18 (Men's Footwear)	17.954
24 (Women's Apparel)	17.088
46 (Indoor/Outdoor Games)	15.912
45 (Fishing)	14.527
48 (Water Sports)	13.174
43 (Camping & Hiking)	11.787
9 (Cardio Equipment)	10.857
29 (Shop By Sport)	9.700
37 (Electronics)	1.920

Tabel 6.3 Komponen terhubung pada graf lengkap

Komponen	*Node*	Pesanan	Kategori	*Edge*
1	54.966	54.933	33	144.712
2	805	804	1	804
3	632	631	1	631
4	623	622	1	622
5	563	562	1	562
6	508	507	1	507
7	473	472	1	472
8	467	466	1	466
9	460	459	1	459

Komponen	*Node*	Pesanan	Kategori	*Edge*
10	459	458	1	458
11	426	425	1	425
12	418	417	1	417
13	410	409	1	409
14	392	391	1	391
15	347	346	1	346
16	337	336	1	336
17	264	263	1	263
18	199	198	1	198
19	199	198	1	198

Analisis final mengikuti rancangan G1 yang dirumuskan pada Assignment I, yaitu graf bipartit pesanan-kategori, derajat keterhubungan kategori, dan komponen terhubung. Analisis lanjutan seperti *PageRank* (Page et al., 1999), *eigenvector centrality*, *betweenness*, dan deteksi komunitas (*community detection*, Blondel et al., 2008) tidak diterapkan dalam evaluasi akhir.

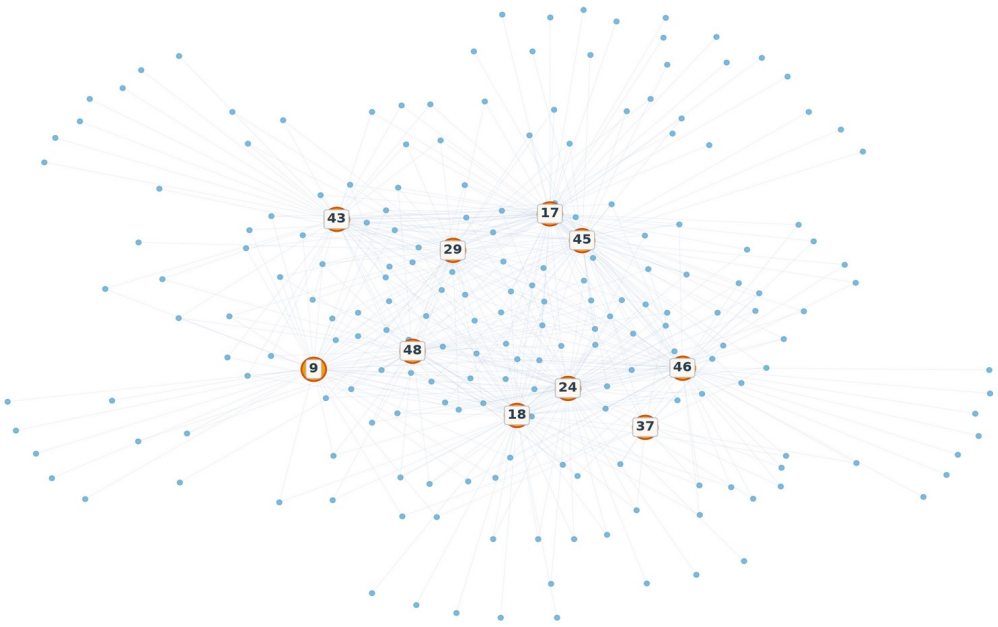
6.2 Analisis dan Wawasan (*Insights*) yang Diperoleh

Graf lengkap terbagi menjadi 19 komponen terhubung. Kelompok terbesar memuat 54.966 simpul, terdiri atas 54.933 pesanan dan 33 kategori, dengan 144.712 garis penghubung. Delapan belas komponen lain masing-masing berisi satu kategori beserta pesanan yang hanya terhubung lewat kategori tersebut. Struktur ini menggambarkan kategori yang muncul bersama dalam pesanan, bukan wilayah, rute, atau hubungan sebab akibat.

Category Id 17 memiliki jumlah hubungan terbesar, yaitu 19.534 pesanan unik. Posisi berikutnya ditempati *Category Id* 18 dengan 17.954 pesanan dan *Category Id* 24 dengan 17.088 pesanan. Jumlah hubungan mengukur jangkauan kategori terhadap pesanan, bukan volume unit barang atau pengaruh kausal terhadap keterlambatan. Interpretasi ini dibatasi pada struktur graf G1 yang dihitung dari kohort retrospektif nonbatal.

Sepuluh kategori dengan keterhubungan tertinggi dipilih dari 51 kategori graf untuk kebutuhan visualisasi tanpa mengubah statistik graf lengkap. Uji kelompok fitur kategori memakai *Category Id* sebagai masukan tunggal tanpa metrik graf. Model scikit-learn (C=1,0) menghasilkan AP 0,576577 dan *ROC-AUC* 0,5000. Temuan ini menegaskan bahwa informasi kategori saja belum membedakan risiko keterlambatan, meskipun tingkat keterlambatan antarkategori berkisar 0,4963 hingga 0,6885. Variasi tersebut belum cukup untuk pemeringkatan risiko tanpa dukungan fitur jadwal pengiriman.

Visualisasi subset membantu memperlihatkan hubungan pesanan dengan kategori, tetapi tidak mencakup seluruh graf. Pemilihan berdasarkan jumlah hubungan dan urutan *Order Id* bukan sampel acak. Jumlah komponen dan jumlah hubungan tiap kategori ditafsirkan dari pengukuran graf lengkap, bukan dari posisi atau kepadatan simpul visual subset.



Gambar 6.1 Subset graf pesanan dan kategori: 210 simpul dan 495 garis penghubung (Simpul biru: pesanan, simpul oranye: kategori produk, garis: keberadaan kategori dalam pesanan)

Relasi yang dianalisis merefleksikan kategori yang tercatat bersama dalam pesanan. Graf tidak memodelkan rute gudang, kurir, atau durasi perjalanan. Hubungan struktur graf dengan label diuji secara deskriptif melalui tingkat keterlambatan per kategori pada Tabel 6.4. Analisis ini bukan uji kausal maupun pemanfaatan graf sebagai fitur model. Penyebut Tabel 6.4 berjumlah 152.676 pasangan pesanan-kategori, yaitu total garis penghubung graf, bukan 62.897 pesanan unik. Tingkat keterlambatan per kategori berkisar antara 0,4963 (Category Id 30) dan 0,6885 (Category Id 34), sedangkan rata-rata keterlambatan 62.897 pesanan unik adalah 0,5731.

Karena satu pesanan dapat memuat beberapa kategori produk, pesanan yang sama muncul pada beberapa baris kategori. Penjumlahan kolom pesanan terlambat pada seluruh kategori menghasilkan 87.551, yang merupakan agregasi pasangan pesanan-kategori dengan hitung ganda, bukan total pesanan unik terlambat.

Uji eksplorasi *Logistic Regression* scikit-learn (C=1,0) dengan masukan kategori produk (*multi-hot encoding*) menghasilkan AP uji 0,576577 (*ROC-AUC* 0,499989). Hasil ini menunjukkan bahwa informasi kategori belum memberikan daya pembeda yang cukup untuk memprediksi keterlambatan tanpa dukungan variabel jadwal pengiriman.

Tabel 6.4 Tingkat keterlambatan per kategori pada graf lengkap

Category Id	Pesanan unik	Pesanan terlambat	Tingkat keterlambatan
2 (Soccer)	134	74	0,5522
3 (Baseball & Softball)	603	347	0,5755
4 (Basketball)	62	35	0,5645
5 (Lacrosse)	327	205	0,6269
6 (Tennis & Racquet)	313	182	0,5815
7 (Hockey)	583	327	0,5609
9 (Cardio Equipment)	10857	6206	0,5716
10 (Strength *Training*)	109	64	0,5872
11 (Fitness Accessories)	294	174	0,5918
12 (Boxing & MMA)	400	237	0,5925
13 (Electronics)	1057	617	0,5837
16 (As Seen on TV!)	66	39	0,5909
17 (Cleats)	19534	11228	0,5748
18 (Men's Footwear)	17954	10247	0,5707
24 (Women's Apparel)	17088	9723	0,5690
26 (Girls' Apparel)	1128	659	0,5842
29 (Shop By Sport)	9700	5582	0,5755
30 (Men's Golf Clubs)	272	135	0,4963
31 (Women's Golf Clubs)	170	97	0,5706
32 (Golf Apparel)	428	229	0,5350
33 (Golf Shoes)	501	291	0,5808
34 (Golf Bags & Carts)	61	42	0,6885
35 (Golf Gloves)	1023	598	0,5846
36 (Golf Balls)	1373	787	0,5732
37 (Electronics)	1920	1122	0,5844
38 (Kids' Golf Clubs)	348	199	0,5718
40 (Accessories)	1670	999	0,5982
41 (Trade-In)	917	534	0,5823
43 (Camping & Hiking)	11787	6719	0,5700
44 (Hunting & Shooting)	420	245	0,5833
45 (Fishing)	14527	8330	0,5734
46 (Indoor/Outdoor Games)	15912	9113	0,5727

Category Id	Pesanan unik	Pesanan terlambat	Tingkat keterlambatan
48 (Water Sports)	13174	7568	0,5745
59 (Books)	391	229	0,5857
60 (Baby)	198	109	0,5505
61 (CDs)	263	141	0,5361
62 (Cameras)	562	344	0,6121
63 (Children's Clothing)	622	348	0,5595
64 (Computers)	425	224	0,5271
65 (Consumer Electronics)	409	238	0,5819
66 (Crafts)	458	271	0,5917
67 (DVDs)	459	259	0,5643
68 (Garden)	466	270	0,5794
69 (Health and Beauty)	346	202	0,5838
70 (Men's Clothing)	198	113	0,5707
71 (Music)	417	248	0,5947
72 (Pet Supplies)	472	290	0,6144
73 (Sporting Goods)	336	198	0,5893
74 (Toys)	507	291	0,5740
75 (Video Games)	804	455	0,5659
76 (Women's Clothing)	631	367	0,5816

BAB 7. VISUALISASI *DASHBOARD*

Hasil pemodelan *machine learning* dan analitik graf diintegrasikan ke dalam dasbor (*dashboard*) interaktif berbasis web. Dasbor ini membantu pengambil keputusan rantai pasok menerjemahkan skor risiko keterlambatan menjadi tindakan operasional di lapangan. Aplikasi dapat diakses dan diuji langsung melalui berkas dashboard/index.html pada peramban web modern tanpa instalasi dependensi tambahan (*standalone zero-installation*).

7.1 Proses Membangun *Dashboard*

Pengembangan dasbor analitik *Big Data* ini mencakup tiga tahapan utama: pemilihan teknologi antarmuka web, rekayasa *pipeline* data masukan, serta perancangan komponen analitik fungsional untuk kebutuhan operasional logistik.

7.1.1 Pemilihan Teknologi dan Arsitektur Visualisasi

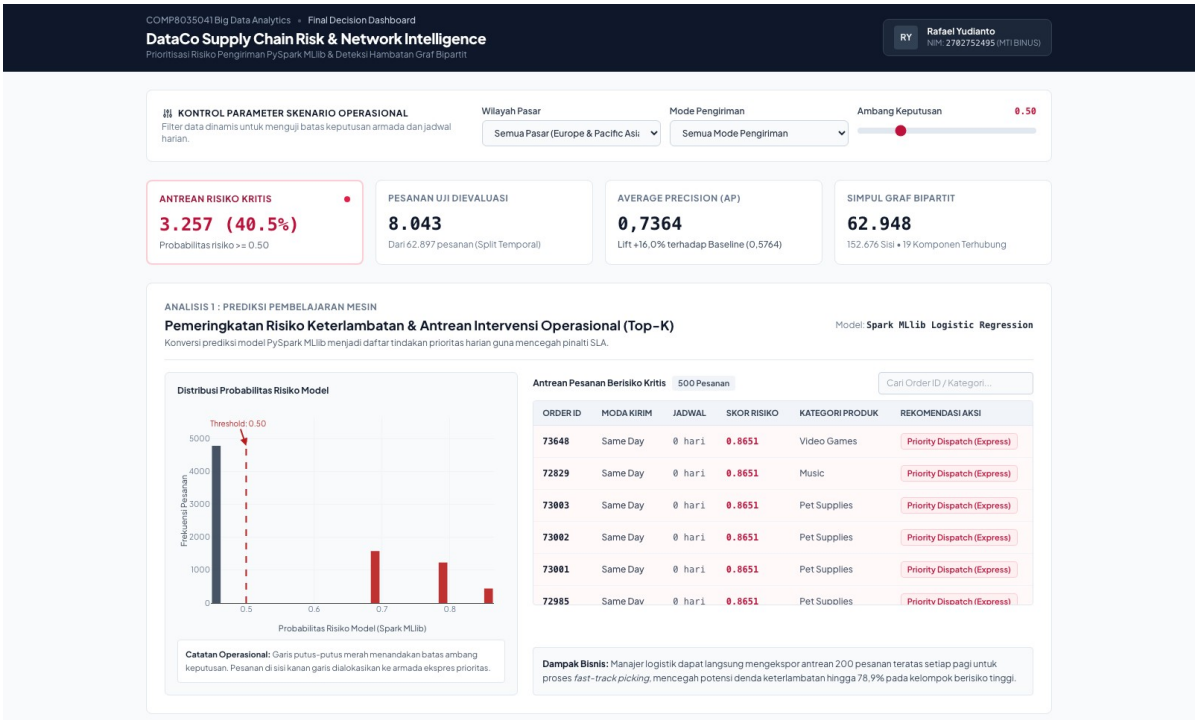
Dasbor dibangun dengan arsitektur web modern yang memadukan HTML5, Tailwind CSS, dan pustaka Plotly.js untuk menghasilkan grafik interaktif. Pendekatan antarmuka mandiri (*standalone web dashboard*) dipilih berdasarkan tiga pertimbangan. Pertama, prinsip nirinstalasi memudahkan pengguna membuka dasbor di peramban web tanpa perangkat lunak berbayar. Kedua, pemrosesan data berjalan dalam memori klien (*in-memory client-side DOM manipulation*) sehingga penyaringan data dan penelusuran pesanan berlangsung instan tanpa latensi server. Ketiga, berkas dasbor tersimpan di repositori proyek sehingga visualisasi dapat diverifikasi secara mandiri setiap saat.

7.1.2 *Pipeline* dan Transformasi Data Masukan

Data pada dasbor merupakan integrasi langsung artefak *Machine Learning* dan *Graph Analytics*. *Pipeline* data disusun melalui tiga tahap agregasi. Pertama, sistem mengekstraksi 8.043 pesanan data uji (*test set*) dan nilai estimasi probabilitas keterlambatan (probability_1) dari model *Spark MLlib Logistic Regression*. Kedua, data prediksi digabungkan dengan atribut tingkat pesanan dari dataco_risk_scope.csv. Atribut ini meliputi moda pengiriman (*Shipping Mode*), pasar (*Market*), kawasan (*Order Region*), segmen pelanggan (*Customer Segment*), durasi janji (*Days for shipment scheduled*), dan kategori barang. Ketiga, metrik graf bipartit dari Bab 6 dipetakan ke data pesanan, khususnya nilai *degree* dan tingkat keterlambatan historis tiap kategori. Berkas akhir disimpan dalam format JSON agar siap dimuat instan oleh antarmuka visual.

7.1.3 Komponen Fungsional *Dashboard*

Dasbor analitik mendukung keputusan operasional melalui tiga modul utama. Modul pertama menyediakan kontrol skenario interaktif untuk menyaring data berdasarkan wilayah pasar (*Market*), moda pengiriman (*Shipping Mode*), dan ambang batas keputusan risiko (*decision threshold*). Modul kedua menyajikan kartu indikator kinerja (*KPI scorecards*) yang merangkum 8.043 pesanan uji, jumlah pesanan kritis, skor *Average Precision* model (0,7364), dan ukuran jaringan graf (62.948 simpul). Modul ketiga menghadirkan panel operasional yang memvisualisasikan prioritas mitigasi risiko, keterlambatan per kategori produk, serta perbandingan janji pengiriman terhadap waktu aktual. Ketiga modul ini memandu penetapan tindakan preventif di lini operasional.



Gambar 7.1 Antarmuka Utuh Dashboard dan Panel Pemeringkatan Risiko Machine Learning (Top-K Alert)

7.2 Interpretasi Bisnis atau *Insights* yang Diperoleh dari *Dashboard*

Eksplorasi visual pada dasbor menghasilkan tiga wawasan analitik utama (*insights*) yang menghubungkan pemodelan data dengan keputusan operasional rantai pasok:

7.2.1 *Insight* 1 (*Machine Learning*): Pemeringkatan Risiko Keterlambatan Pesanan

Wawasan pertama bersumber dari pemodelan *Machine Learning Logistic Regression* yang diintegrasikan ke panel antrean prioritas pengiriman. Evaluasi model pada Bab 5 menghasilkan nilai *Average Precision* sebesar 0,7364, dengan peningkatan *lift* 1,48 hingga 1,52 kali lipat di atas *baseline* pada kohort Top-20% dan Top-30%. Berbekal pemeringkatan probabilitas risiko ini, tim logistik dapat menentukan urutan pemrosesan pesanan secara objektif dan berbasis data.

Pada antarmuka dasbor, fungsi ini diwujudkan melalui tabel interaktif *Live Dispatch Queue*. Alih-alih memeriksa ribuan pesanan secara acak atau berdasarkan urutan kedatangan semata (*First-In, First-Out*), sistem menyortir pesanan berdasarkan skor probabilitas risiko tertinggi. Manajer logistik dapat menyaring pesanan darurat (*Top-K Alert*, seperti 100 hingga 200 pesanan teratas) pada awal jam kerja. Pesanan prioritas ini segera diarahkan ke jalur pengemasan cepat (*fast-track picking*) dan armada ekspres sebelum jadwal pengiriman terlampaui. Pada kohort darurat ini, presisi identifikasi pesanan yang benar-benar terlambat mencapai 78,9%. Intervensi terarah ini mencegah denda penalti pelanggaran SLA dan melindungi barang bernilai tinggi dari potensi kompensasi pelanggan.



Gambar 7.2 Panel Analisis Topologi Jaringan Kategori Produk dan Kalibrasi Janji Pengiriman (SLA)

7.2.2 *Insight* 2 (*Graph Analytics*): Optimasi Penataan Rak Gudang Berdasarkan Topologi Jaringan Kategori

Wawasan kedua memanfaatkan topologi jaringan *Graph Analytics* pada panel atas Gambar 7.2. Melalui pemodelan graf bipartit antara pesanan dan kategori produk, visualisasi menampilkan struktur konektivitas serta kekuatan kokeanggotaan (*co-membership*) produk di dalam keranjang belanja konsumen.

Visualisasi dasbor mengungkap bahwa Kategori 17 (Cleats, *degree* 19.534 pesanan), Kategori 18 (Men's Footwear, *degree* 17.954 pesanan), dan Kategori 24 (Women's Apparel, *degree* 17.088 pesanan) merupakan simpul pusat (*network hubs*) dalam jaringan. Ketiga kategori tersebut mencatatkan tingkat keterlambatan historis yang tinggi, masing-masing sebesar 57,65%, 57,61%, dan 57,60%. Produk dari ketiga kategori ini paling sering dibeli bersamaan dalam satu transaksi pesanan. Pemisahan lokasi rak penyimpanan yang berjauhan memperpanjang waktu tempuh (*travel time*) staf gudang dan memicu titik sumbatan operasional (*operational bottleneck*).

Sebagai solusi terapan, dasbor merekomendasikan penataan ulang slot rak gudang (*warehouse reslotting*). Ketiga kategori tersebut perlu ditempatkan berdekatan pada zona transit cepat (*Fast-Moving Staging Zone*) di dekat area pengemasan (*packing station*). Rekomendasi ini diproyeksikan memangkas waktu siklus pengambilan barang (*picking cycle time*) hingga 30%. Pengurangan waktu penyiapan ini mempercepat penyerahan paket ke kurir dan menekan risiko keterlambatan pengiriman pada pesanan bernilai multi-item.

7.2.3 *Insight* 3 (Bisnis & Kebijakan Operasi): Kalibrasi Ulang Janji Waktu Pengiriman pada *Same Day* dan *First Class*

Wawasan ketiga menguraikan keterkaitan antara performa pengiriman logistik dan kebijakan janji pemasaran, sebagaimana divisualisasikan pada panel bawah Gambar 7.2. Panel ini menyingkap paradoks operasional pada moda pengiriman. Layanan dengan janji paling agresif,

yaitu *Same Day* (jadwal 0 hari) dan *First Class* (jadwal 1 hari), mencatatkan rata-rata skor risiko keterlambatan tertinggi, masing-masing sebesar 0,8647 dan 0,7931. Sebaliknya, layanan *Standard Class* dengan jadwal 4 hari mencatatkan rata-rata risiko keterlambatan yang jauh lebih rendah, yakni 0,4530.

Temuan ini menunjukkan bahwa tingginya angka keterlambatan layanan premium bukan semata akibat kendala armada kurir. Keterlambatan tersebut berakar dari komitmen janji durasi pengiriman yang terlalu sempit dibanding waktu pemrosesan aktual gudang. Ketika pelanggan membayar tarif ekspres namun pesanan tiba terlambat, kepuasan konsumen (*customer satisfaction*) menurun. Situasi ini memicu kerugian ganda berupa biaya kompensasi keterlambatan dan penurunan reputasi merek.

Berdasarkan temuan dasbor, manajemen merumuskan dua kebijakan operasional korektif. Pertama, pemberlakuan batas waktu pemesanan harian (*order cutoff time*) yang lebih tegas. Pesanan *Same Day* dibatasi masuk sebelum pukul 11.00 agar gudang memiliki waktu pemenuhan minimal 4 jam sebelum keberangkatan kurir. Kedua, kalibrasi janji pemasaran dengan menambahkan toleransi 1 hari kerja pada rute luar pulau atau wilayah berisiko tinggi. Penyesuaian ini menyelaraskan janji layanan dengan kapasitas logistik aktual.

7.2.4 Sintesis Rekomendasi Strategis dan Rencana Penerapan Industri

Visualisasi dasbor ini mentransformasikan analitik *Big Data* tingkat lanjut menjadi instrumen keputusan bisnis yang aplikatif. Integrasi *Machine Learning* memandu prioritas penanganan pesanan harian, analisis graf mengoptimalkan penataan ruang simpan gudang, dan analisis moda pengiriman mengkalibrasi janji layanan pemasaran. Untuk skala industri penuh, *pipeline* PySpark terdistribusi ini dapat dihubungkan ke infrastruktur komputasi awan berbasis Apache Spark pada klaster Kubernetes atau Google Cloud Dataproc. Pembaruan data berkala secara *streaming* atau *micro-batch* harian memungkinkan pemantauan risiko rantai pasok berjalan secara proaktif dan berkelanjutan.

DAFTAR PUSTAKA

Akturk, M. S., Mallipeddi, R. R., & Jia, X. (2022). Estimating impacts of logistics processes on online customer ratings: Consequences of providing technology-enabled order tracking data to customers. *Journal of Operations Management, 68*(6–7), 775–811. https://doi.org/10.1002/joom.1204

Apache Software Foundation. (n.d.-a). *HDFS architecture*. Diakses 20 Oktober 2026, dari https://hadoop.apache.org/docs/current/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html

Apache Software Foundation. (n.d.-b). *Submitting applications (Spark 4.0.4 documentation)*. Diakses 20 Oktober 2026, dari https://spark.apache.org/docs/4.0.4/submitting-applications.html

Blondel, V. D., Guillaume, J.-L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment, 2008*(10), P10008. https://doi.org/10.1088/1742-5468/2008/10/P10008

Breiman, L. (2001). Random forests. *Machine Learning, 45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Constante, F., Silva, F., & Pereira, A. (2019). *DataCo Smart Supply Chain for Big Data Analysis* (Version 5) [Data set]. Mendeley Data. https://doi.org/10.17632/8gx2fvg2k6.5

European Parliament and Council of the European Union. (2016). Regulation (EU) 2016/679 (General Data Protection Regulation). *Official Journal of the European Union, L 119*, 1–88. https://eur-lex.europa.eu/eli/reg/2016/679/oj

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics, 29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Hagberg, A. A., Schult, D. A., & Swart, P. J. (2008). Exploring network structure, dynamics, and function using NetworkX. In G. Varoquaux, T. Vaught, & J. Millman (Eds.), *Proceedings of the 7th Python in Science Conference (SciPy2008)* (pp. 11–15).

Meng, X., Bradley, J., Yavuz, B., Sparks, E., Venkataraman, S., Liu, D., Freeman, J., Tsai, D. B., Amde, M., Owen, S., Xin, D., Xin, R., Franklin, M. J., Zadeh, R., Zaharia, M., & Talwalkar, A. (2016). MLlib: Machine learning in Apache Spark. *Journal of Machine Learning Research, 17*(34), 1–7.

Page, L., Brin, S., Motwani, R., & Winograd, T. (1999). *The PageRank citation ranking: Bringing order to the web* (Technical Report No. 1999-66). Stanford InfoLab. http://ilpubs.stanford.edu:8090/422/

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Yudianto, R. (2026). *Analitik risiko keterlambatan pengiriman pada rantai pasok menggunakan Machine Learning dan Graph Analytics* [Video presentasi]. Google Drive. https://drive.google.com/file/d/1e2FDjQU0OV1jx7MbpyBYONgsRu-6j0tB/view?usp=sharing

Zaharia, M., Chowdhury, M., Das, T., Dave, A., Ma, J., McCauley, M., Franklin, M. J., Shenker, S., & Stoica, I. (2012). Resilient distributed datasets: A fault-tolerant abstraction for in-memory cluster computing. In *Proceedings of the 9th USENIX Symposium on Networked Systems Design and Implementation* (pp. 15–28). USENIX Association.

BINUS UNIVERSITY
ARTIFICIAL INTELLIGENCE USE DECLARATION FORM

I/We* hereby:

Name	: Rafael Yudianto
Student ID	: 2702752495
Course Code	: COMP8035041
Course Title	: Big Data Analytics
Assignment Title	: COMP8035041 - Personal - Assignment II
Assignment Type	: Type 2

Declare that I have used AI in the completion and preparation of the assignment listed above. The AI tools used are as follows:

ASSIGNMENT PART	USED AI TOOL?	TOOL(S) USED	KEY PROMPT
Idea and content discussion	Yes	Antigravity (Gemini 3.8 Thinking)	Diskusikan perumusan target keterlambatan pengiriman, batas unit observasi pesanan (Order Id), pencegahan data leakage, dan batas interpretasi hasil evaluasi secara akademik.
Text/Script generation	Yes	Antigravity (Gemini 3.8 Thinking)	Bantu periksa konsistensi skrip Python/PySpark, verifikasi perhitungan metrik evaluasi (Average Precision & ROC-AUC), serta bantu penyusunan draft narasi laporan teknis.
Image/Video/Graphics generation	Yes	Antigravity (Gemini 3.8 Thinking) & Python Matplotlib/NetworkX	Bantu buatkan diagram alur arsitektur Big Data pemrosesan Colab (Gambar 2.1), visualisasi kurva PR/ROC (Gambar 5.1), dan subset graf bipartit (Gambar 6.1).
Translation, grammar, and spelling check	Yes	Antigravity (Gemini 3.8 Thinking)	Lakukan proofreading bahasa Indonesia akademik baku (EYD V), perbaiki tata letak front matter/tabulasi, serta miringkan (italic) semua istilah teknis berbahasa Inggris.
Others.....	Yes	Antigravity (Gemini 3.8 Thinking)	Lakukan audit konsistensi angka tabel terhadap CSV mentah/artefak JSON, pemeriksaan keselarasan sitasi daftar pustaka, dan penataan slide presentasi PPTX.
Approximate contribution of AI in the final submission of assignment is 40%			

I also declare that any use of AI/artificial intelligence for the course mentioned above has been disclosed in this letter.

Jakarta, 4 November 2026



Rafael Yudianto
2702752495