ANALITIK RISIKO KETERLAMBATAN PENGIRIMAN PADA RANTAI PASOK MENGGUNAKAN *MACHINE LEARNING* DAN *GRAPH ANALYTICS*

Studi Kasus: DataCo Smart Supply Chain — Assignment II

Nama: Rafael Yudianto

NIM: 2702752495

Kelas: LCD3

Dosen: Dr. Ir. Edy Irwansyah, S.T., M.Si., IPM

Mata Kuliah: COMP8035041 *Big Data Analytics*

PROGRAM STUDI MAGISTER TEKNIK INFORMATIKA

BINUS GRADUATE PROGRAM

Tanggal pengumpulan: 30 Oktober 2026

DAFTAR ISI

DAFTAR TABEL....3
DAFTAR GAMBAR....4
BAB 1. PENDAHULUAN....5
1.1 Latar Belakang Masalah....5
1.2 Market dan Business Drivers....6
1.3 Pemangku Kepentingan yang Terlibat....6
BAB 2. RANCANGAN SOLUSI BIG DATA....7
2.1 Metode Pengumpulan Data (Data Ingestion)....7
2.2 Teknologi Penyimpanan Data....7
2.3 Processing Framework....8
BAB 3. TATA KELOLA IT....10
3.1 Security....10
3.2 Compliance....10
3.3 Privasi Data....10
3.4 Kualitas Data....10
BAB 4. DATA....12
4.1 Deskripsi Data....12
4.1.1 Pembersihan Data Transaksi....12
4.1.2 Organisasi Data....14
4.2 Model Data dan Operasi Data....14
4.3 Dataset untuk Diolah Menggunakan Machine Learning....16
BAB 5. MACHINE LEARNING....17
5.1 Data Preprocessing....17
5.2 Feature Engineering....18
5.3 Algoritma....19
5.4 Proses Pengembangan Model dengan dan tanpa Spark MLlib....20
5.5 Evaluasi Model....21
5.6 Analisis....22
BAB 6. GRAPH ANALYTICS....26
6.1 Pengembangan Graph....26
6.2 Analisis dan Insight yang Diperoleh....27
BAB 7. KESIMPULAN DAN REKOMENDASI....31
DAFTAR PUSTAKA....32
BINUS UNIVERSITY ARTIFICIAL INTELLIGENCE USE DECLARATION FORM....33

DAFTAR TABEL

Tabel 1.1 Market dan business drivers....6
Tabel 1.2 Pemangku kepentingan....6
Tabel 2.1 Implementasi dan batas pengujian komponen....7
Tabel 2.2 Rancangan dan implementasi penyimpanan....8
Tabel 3.1 Pemeriksaan kualitas data dan keterbatasannya....11
Tabel 4.1 Sumber data....12
Tabel 4.2 Pemetaan nama kolom....13
Tabel 4.3 Tahapan pembersihan transaksi....13
Tabel 4.4 Organisasi data....14
Tabel 4.5 Peran variabel....15
Tabel 4.6 Model dan operasi data....15
Tabel 4.7 Cakupan dataset Assignment II....16
Tabel 5.1 Fitur dan representasi masukan model....18
Tabel 5.2 Parameter Logistic Regression....19
Tabel 5.3 Pembagian temporal data pesanan....20
Tabel 5.4 Konfigurasi final dua implementasi Logistic Regression....21
Tabel 5.5 Hasil evaluasi pada data test....22
Tabel 5.6 Hasil evaluasi pada data validation....22
Tabel 5.7 Ringkasan pengujian top-k pada data test....23
Tabel 5.8 Distribusi skor peluang: test (Colab dan lokal) dan validation (lokal)....24
Tabel 6.1 Definisi graf pesanan dan kategori....26
Tabel 6.2 Degree sepuluh kategori pada graf lengkap....26
Tabel 6.3 Komponen terhubung pada graf lengkap....27
Tabel 6.4 Tingkat keterlambatan per kategori pada graf lengkap....29

DAFTAR GAMBAR

Gambar 2.1 Arsitektur dan Alur Pemrosesan DataCo pada Assignment II.....9
Gambar 6.1 Subset graf pesanan dan kategori: 210 node dan 495 edge.....28

BAB 1. PENDAHULUAN

1.1 Latar Belakang Masalah

Penelitian menggunakan DataCo Smart Supply Chain versi 5 dari Constante et al. (2019), DOI 10.17632/8gx2fvg2k6.5, dengan lisensi CC BY 4.0. Pengunduhan dan pemeriksaan ulang ketiga CSV telah dilakukan. Data transaksi berisi 180.519 baris dan 53 kolom, dengan tanggal pesanan 1 Januari 2015 hingga 31 Januari 2018. Dataset yang digunakan tersedia pada DOI https://doi.org/10.17632/8gx2fvg2k6.5, sedangkan seluruh analisis dijalankan menggunakan skrip Python internal dan notebook Colab pendukung.

Penelitian ini melanjutkan studi kasus DataCo Smart Supply Chain pada Assignment I dengan tujuan memperkirakan risiko keterlambatan pengiriman pada tingkat pesanan. Pengolahan mencakup pembersihan data, pembentukan fitur, pelatihan Logistic Regression menggunakan scikit-learn dan Spark MLlib, evaluasi prediksi, serta analisis graf pesanan dan kategori. Pelatihan scikit-learn, eksekusi Spark MLlib, evaluasi, dan komputasi graf dijalankan pada runtime Google Colab menggunakan data historis.

Kamus data mendeskripsikan Days for shipping (real) sebagai “Actual shipping days of the purchased product”, Days for shipment (scheduled) sebagai “Days of scheduled delivery of the purchased product”, Shipping date (DateOrders) sebagai “Exact date and time of shipment”, dan Late_delivery_risk sebagai indikator keterlambatan pengiriman. Target penelitian mengikuti definisi Late_delivery_risk pada sumber. Definisi tersebut tidak secara khusus membuktikan keterlambatan penyerahan fisik barang kepada kurir. Kamus data resmi memuat 52 baris deskripsi, sedangkan berkas transaksi memuat 53 kolom. Satu-satunya kolom tanpa deskripsi adalah Order Zipcode, yang kosong pada 155.679 dari 180.519 baris (86,24%) dan tidak dipakai dalam pengolahan maupun model.

Pemeriksaan terhadap 180.519 transaksi menunjukkan bahwa selisih shipping_date − order_date sama dengan Days for shipping (real) pada 170.782 baris. Pada 5.080 baris, selisih timestamp lebih besar 0,5 hari (+0,5 hari); pada 4.657 baris, selisihnya lebih kecil 0,5 hari (−0,5 hari). Dengan demikian, durasi sumber tidak identik dengan selisih timestamp untuk seluruh data. Pada 172.765 item nonbatal, Late_delivery_risk konsisten dengan kondisi durasi aktual melebihi durasi terjadwal. Konsistensi ini mendukung penggunaan label sumber, tetapi tidak menetapkan makna operasional penyerahan barang kepada kurir. Secara matematis, Δ = (shipping date − order date) dalam hari, dan nilai Δ − Days for shipping (real) hanya mengambil tiga nilai, yaitu 0 hari pada 170.782 baris, +0,5 hari pada 5.080 baris, dan −0,5 hari pada 4.657 baris; tidak ada baris dengan selisih di luar ±0,5 hari. Pemeriksaan ulang terhadap DataCoSupplyChainDataset.csv mereproduksi ketiga angka tersebut.

Akturk et al. (2022) melaporkan hubungan durasi pemrosesan dan pengiriman dengan penilaian pelanggan. Literatur tersebut bukan pengukuran dampak bisnis DataCo. Proyek menghasilkan probabilitas dan prediksi historis, tetapi belum mengukur biaya, kepuasan pelanggan, keberhasilan intervensi atau penggunaan daftar prioritas operasional.

Pemeriksaan memperoleh 172.765 item nonbatal dalam 62.897 pesanan. Sebanyak 98.977 item berlabel 1 dan 73.788 berlabel 0. Persentase item terlambat dihitung pada Persamaan (1.1), bukan persentase pesanan atau pelanggan. Sebanyak 7.754 item Shipping canceled dikeluarkan sesuai aturan cakupan. Distribusi ini merupakan hasil deskriptif, bukan kinerja model.

$$P = \frac{98.977}{172.765} \times 100\,\% \approx 57{,}29\,\% \qquad (1.1)$$

Data transaksi berukuran 95.910.149 byte (sekitar 91,5 MiB) dan clickstream berukuran 95.446.364 byte (sekitar 91,0 MiB). Volume tersebut diproses pada runtime Google Colab. Apache Spark digunakan untuk menerapkan pemrosesan data dan machine learning dalam kerangka yang mendukung pengembangan terdistribusi; kebutuhan cluster produksi maupun peningkatan kinerjanya tidak diuji dalam penelitian ini. Dengan ukuran tersebut dan eksekusi pada satu mesin, penelitian ini merupakan demonstrasi penerapan ekosistem teknologi Big Data pada data historis, bukan bukti skalabilitas pemrosesan terdistribusi.

1.2 *Market* dan *Business Drivers*

Market drivers meliputi ekspektasi pelanggan terhadap estimasi dan pelacakan serta persaingan janji waktu pengiriman. *Business drivers* meliputi beban layanan pelanggan, perencanaan kapasitas gudang, dan pemeliharaan tingkat layanan. Keluaran yang diusulkan adalah prioritas internal; manfaat penurunan keterlambatan atau biaya belum diuji. Faktor-faktor tersebut merupakan asumsi kebutuhan bisnis yang dipakai untuk merumuskan masalah, bukan hasil pengukuran dataset ini, sehingga besaran pengaruhnya tidak diuji dalam penelitian ini.

Tabel 1.1 *Market* dan *business drivers*

Jenis	Pendorong	Kebutuhan analitik
Market	Ekspektasi estimasi dan pelacakan; persaingan janji pengiriman	Informasi risiko lebih awal untuk membantu pengelolaan ekspektasi
Business	Beban layanan pelanggan dan operasional; kapasitas gudang; tingkat layanan	Daftar prioritas pesanan pada siklus operasional yang dipilih

1.3 Pemangku Kepentingan yang Terlibat

Operations/Logistics merupakan calon pengguna utama skor risiko untuk meninjau prioritas penanganan pesanan. CS Lead (koordinator layanan pelanggan) dapat menggunakan informasi risiko untuk mendukung komunikasi pelanggan, sedangkan manajemen memerlukan ringkasan layanan. Data/IT serta fungsi keamanan dan privasi mendukung pengelolaan sistem. Peran tersebut merupakan rancangan pemanfaatan keluaran, bukan penerapan operasional yang telah dievaluasi.

Tabel 1.2 Pemangku kepentingan

Pihak	Informasi	Tindakan
Operations / Logistics	Daftar pesanan dan skor risiko	Meninjau prioritas penanganan
CS Lead	Pesanan berisiko	Mengelola komunikasi dan ekspektasi
Manajemen	Ringkasan wilayah, kategori, moda	Meninjau tingkat layanan
Data/IT	Status *pipeline* dan validasi	Menangani kegagalan pengolahan
Keamanan / privasi	Hak akses dan audit	Mengawasi penggunaan data

BAB 2. RANCANGAN SOLUSI BIG DATA

Arsitektur pada Assignment I menempatkan Apache Hadoop sebagai ekosistem pendukung, Hadoop Distributed File System (HDFS) sebagai penyimpanan, dan Apache Spark sebagai mesin pemrosesan. HDFS merupakan bagian dari Hadoop, sedangkan MapReduce tidak digunakan. Implementasi eksperimen membaca dan menulis data pada *filesystem* lokal (file:///). Pengujian HDFS hanya mencakup penulisan dan pembacaan berkas sederhana, bukan pengolahan dataset lengkap.

2.1 Metode Pengumpulan Data (*Data Ingestion*)

Ketiga CSV DataCo versi 5 diunduh dari sumber resmi. Data historis dibaca secara batch menggunakan Python. Ingestion transaksi harian dan streaming clickstream tidak dijalankan pada tahap pelaksanaan yang dilaporkan.

Pengolahan menggunakan *snapshot* historis, bukan *feed* transaksi operasional. Tidak ada klaim kesegaran *real-time*, pembaruan harian produksi, atau respons per detik dalam hasil proyek ini.

Pemeriksaan *clickstream* memperoleh rentang 1 September 2017 pukul 06:00 hingga 31 Januari 2018 pukul 23:58. Struktur, nilai kosong, dan kesamaan baris telah diperiksa. *Clickstream* belum digabungkan dengan transaksi; manfaat prediktif dan hubungan sebab-akibat tidak dinyatakan sebagai hasil.

Tabel 2.1 Implementasi dan batas pengujian komponen

Fungsi	Implementasi	Belum dilaksanakan
Ingestion	Unduh *snapshot* CSV; verifikasi hash; baca *batch* Python lokal	Pemuatan seluruh CSV ke HDFS; *batch* terjadwal
Storage	HDFS *single-node*; tulis/baca berkas uji	Lapisan dataset lengkap; konversi Parquet/JSON
Processing	Pembersihan Python; pembentukan *edge* graf dengan Spark; pelatihan dan evaluasi lokal	*Streaming* dan *benchmark multi-node* belum dilakukan
Analytics/consumption	Probabilitas, prediksi, metrik, dan graf tersimpan secara lokal	Penggunaan operasional dan intervensi tidak diuji

2.2 Teknologi Penyimpanan Data

Rancangan penyimpanan memisahkan data mentah, data bersih, dan data siap analitik dalam lapisan yang dapat dibaca Spark. HDFS menjadi pilihan penyimpanan pada rancangan tersebut. Dalam implementasi, ketiga lapisan direpresentasikan oleh direktori dan berkas lokal. Pengujian berkas sederhana pada HDFS menunjukkan fungsi tulis dan baca dasar, tetapi dataset penelitian tidak dimuat secara lengkap ke HDFS.

HDFS menggunakan NameNode untuk mengelola metadata dan DataNode untuk menyimpan blok data. Konfigurasi uji lokal menggunakan satu DataNode dengan dfs.replication=1. Konfigurasi ini tidak menyediakan replikasi lintas mesin sehingga tidak menguji toleransi kegagalan *node*, *high availability*, atau skalabilitas produksi. Data historis disimpan sebagai CSV untuk pengolahan *batch*. Parquet untuk transaksi bersih dan JSON untuk *clickstream* merupakan format dalam rancangan, bukan hasil konversi yang telah digunakan. Penjelasan arsitektur HDFS mengacu pada dokumentasi Apache Software Foundation (n.d.-a).

Tabel 2.2 Rancangan dan implementasi penyimpanan

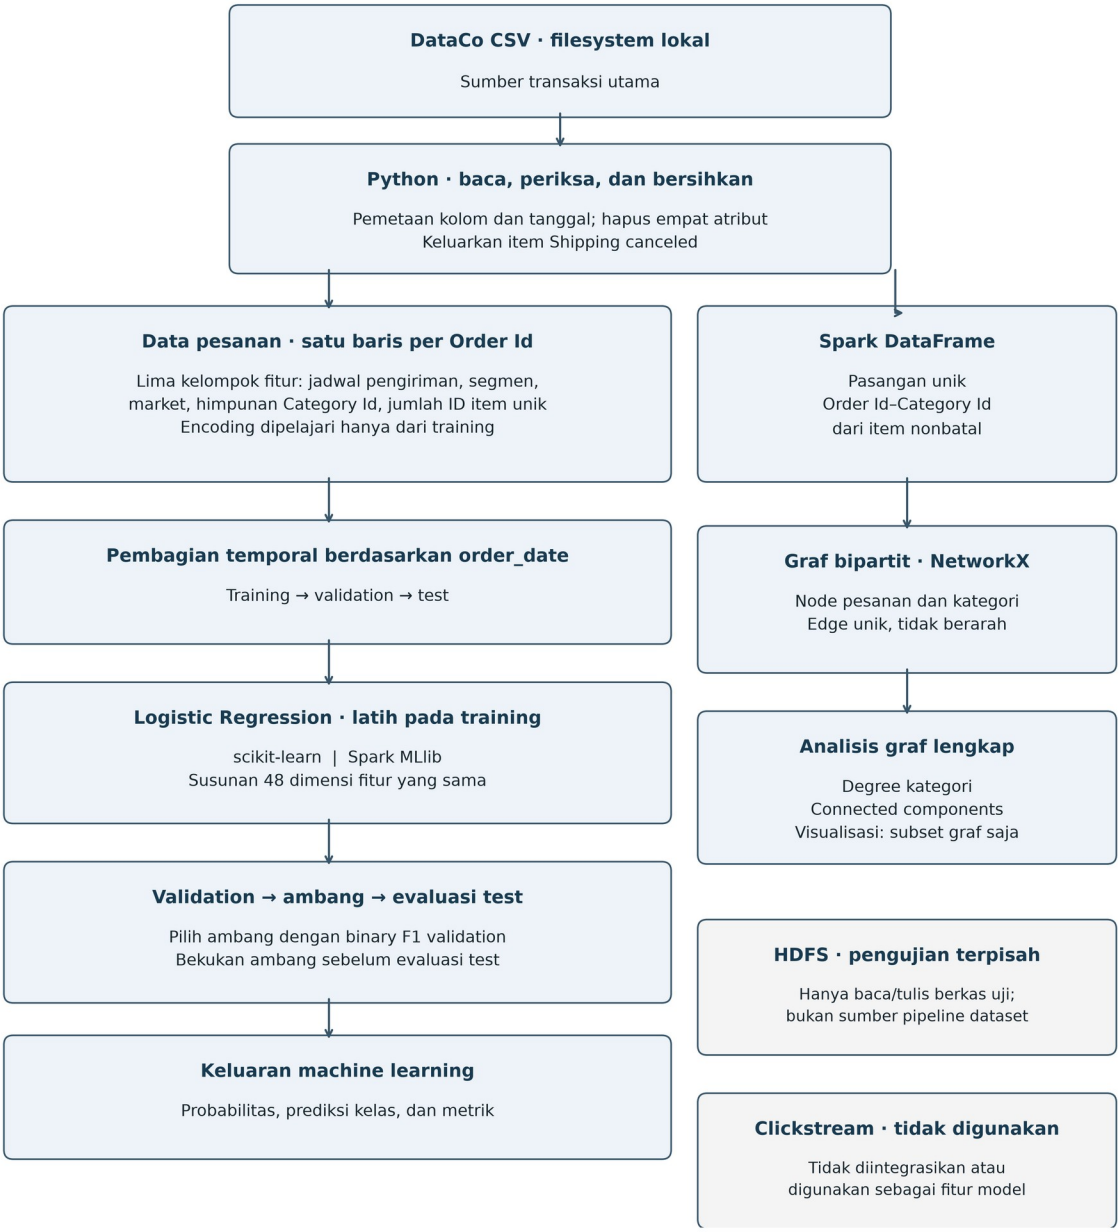
Komponen	Kondisi aktual	Status desain
Apache Hadoop / HDFS	Hadoop 3.4.3; HDFS *single-node*; replication=1	Penyimpanan lapisan data dalam rancangan
CSV mentah/bersih	Berkas lokal tersedia dan diperiksa	Dataset lengkap belum dimuat ke HDFS
Parquet transaksi	Tidak ada konversi terverifikasi	Format target hasil pembersihan
JSON *clickstream*	Sumber aktual masih CSV	Format target; bukan hasil tersedia

2.3 *Processing Framework*

Lingkungan pengujian awal menggunakan macOS dengan Python 3.12.15, Spark/PySpark 3.5.9, dan Java 17.0.20.1. Spark menggunakan mode local[2], yaitu dua thread pemrosesan lokal, dengan fs.defaultFS=file:///. Dengan demikian, pembacaan dataset pada eksperimen awal berlangsung melalui filesystem setempat, bukan melalui layanan HDFS. Lingkungan ini digunakan untuk validasi prototipe; sedangkan seluruh angka hasil eksperimen dan eksekusi final pada Bab 5 diambil dari lingkungan Google Colab dengan Spark 4.0.4 (Bab 5.4).

Spark mendukung transformasi tabular, agregasi, dan *machine learning* dalam satu ekosistem pemrosesan. Pada penelitian ini, Spark MLlib digunakan untuk pelatihan Logistic Regression, sedangkan Spark DataFrame digunakan untuk membentuk relasi unik pesanan dan kategori. Pembersihan data dan evaluasi juga memanfaatkan Python. *Benchmark* waktu, penggunaan memori, *throughput*, dan skalabilitas *multi-node* tidak dilakukan, sehingga tidak ditarik kesimpulan bahwa Spark atau HDFS lebih cepat daripada pengolahan lokal. Dasar pemrosesan Spark mengacu pada Zaharia et al. (2012) dan dokumentasi Apache Spark (Apache Software Foundation, n.d.-b).

Gambar 2.1 merangkum alur aktual dari CSV transaksi pada *filesystem* lokal menuju dua jalur analisis: *machine learning* dan graf pesanan–kategori. HDFS ditampilkan terpisah karena pengujiannya hanya mencakup baca dan tulis berkas sederhana. *Clickstream* tidak digunakan dalam model maupun integrasi fitur.



Gambar 2.1 Arsitektur dan Alur Pemrosesan DataCo pada Assignment II

Alur pengolahan mencakup pemetaan nama kolom, konversi tanggal, penghapusan empat atribut, perhitungan late_days untuk pemeriksaan, dan pemilihan pesanan nonbatal. Data kemudian diagregasi menjadi satu observasi per Order Id, diubah menjadi fitur, dan digunakan untuk menghasilkan probabilitas serta prediksi. Penerapan daftar prioritas operasional dan pemrosesan *streaming* tidak termasuk pengujian.

BAB 3. TATA KELOLA IT

3.1 *Security*

Konfigurasi HDFS menetapkan alamat *loopback* untuk NameNode dan DataNode. Log Spark menunjukkan koneksi *driver* pada 127.0.0.1 dan *authentication disabled*. Pembatasan jaringan mengurangi paparan eksternal, tetapi tidak menggantikan autentikasi atau otorisasi. Enkripsi data, kontrol akses produksi, dan audit keamanan menyeluruh belum dibuktikan.

Pembersihan transaksi menghapus Customer Email, Customer Password, Product Description, dan Product Image. Penghapusan ini mengurangi atribut sensitif dan atribut yang tidak digunakan, tetapi tidak menjadikan seluruh dataset anonim. Atribut identitas dan lokasi lain tetap memerlukan penilaian sebelum pemanfaatan lebih lanjut.

Berkas mentah tetap memuat atribut sensitif tersebut. Ketiga CSV sumber disimpan pada penyimpanan lokal komputer kerja penulis dan tidak diunggah ke repositori publik; pembatasan akses bergantung pada akun pengguna perangkat, bukan pada mekanisme otentikasi terpusat, karena konfigurasi autentikasi HDFS dinonaktifkan pada pengujian lokal. Kebijakan retensi formal, enkripsi at-rest, dan kontrol akses tingkat produksi belum ditetapkan maupun diuji dalam penelitian ini, sehingga penghapusan kolom pada data bersih tidak boleh dibaca sebagai jaminan bahwa risiko privasi pada lapisan mentah telah hilang.

Belum dilakukan simulasi insiden, pengujian pemulihan, atau penegakan retensi otomatis. Prosedur keamanan operasional pada desain awal tetap berada di luar hasil implementasi yang telah diuji.

3.2 *Compliance*

DataCo versi 5 dirilis dengan lisensi CC BY 4.0 (Constante et al., 2019), DOI 10.17632/8gx2fvg2k6.5. Perubahan data meliputi pemetaan kolom, konversi representasi tanggal, penghapusan empat kolom, penambahan late_days, dan seleksi nonbatal. Lisensi tidak membuktikan anonimisasi atau kepatuhan hukum menyeluruh.

3.3 Privasi Data

General Data Protection Regulation (GDPR; European Parliament and Council of the European Union, 2016) digunakan sebagai referensi prinsip, bukan penetapan yurisdiksi atau bukti kepatuhan hukum. Empat kolom dihapus dari transaksi bersih, tetapi alamat IP masih tersimpan pada sumber *clickstream* untuk pemeriksaan. Dataset belum dinyatakan anonim dan lapisan analitik *clickstream* belum dibangun.

3.4 Kualitas Data

Pemeriksaan kualitas mencakup jumlah baris dan kolom, identitas unik, konversi tanggal, duplikasi baris penuh, nilai kosong, dan hubungan label dengan durasi pada cakupan nonbatal. Pemeriksaan kebaruan operasional, perubahan distribusi, rentang seluruh atribut, dan karantina otomatis tidak dilakukan. Nilai late_days negatif menunjukkan durasi aktual yang lebih pendek daripada jadwal dan tidak otomatis merupakan kesalahan data.

Integritas ketiga CSV diperiksa sebelum eksperimen. Pemeriksaan awal mencocokkan kondisi berkas dengan metadata sumber resmi; eksperimen selanjutnya menggunakan acuan lokal tersebut. Kecocokan data mendukung integritas berkas, tetapi tidak membuktikan ketepatan seluruh informasi bisnis maupun kepatuhan hukum.

Tabel 3.1 Pemeriksaan kualitas data dan keterbatasannya

Pemeriksaan	**Hasil pemeriksaan**	**Batas**
Jumlah, tipe, nilai kosong, ID unik	Diperiksa ulang dari CSV sumber	Pemeriksaan menggunakan Python
Jumlah keluaran bersih	180.519 dan 172.765 baris, masing-masing 50 kolom	Keluaran transaksi, bukan jumlah observasi model
Hash sumber	Metadata resmi tersedia	Ketiga hash cocok dengan sumber resmi
Duplikasi *clickstream*	3.249 baris identik terverifikasi	Identik tidak membuktikan kejadian sama
Makna operasional label	Label konsisten dengan perbandingan durasi	Tidak menetapkan makna penyerahan fisik kepada kurir
Kontrol operasional	Rancangan	Belum diuji

BAB 4. DATA

4.1 Deskripsi Data

Jumlah pada Tabel 4.1 diperoleh dari pembacaan ulang berkas resmi. Ketiga berkas berbentuk CSV (comma-separated values), yaitu berkas teks sederhana yang menyusun data dalam baris dan kolom sehingga dapat dibuka oleh program pengolah tabel. Penerbit menyebut data catatan kunjungan situs (clickstream) sebagai data tidak terstruktur (unstructured), padahal berkas tokenized_access_logs.csv yang kami periksa sudah berbentuk tabel dengan delapan kolom tetap. Perbedaan sebutan ini kami catat karena memengaruhi cara pengolahan, sedangkan pilihan format JSON pada rancangan tidak mengubah struktur CSV historis yang sudah ada. Tabel 4.1 dibaca per baris: kolom jumlah adalah hasil hitung ulang atas berkas, sedangkan kolom terakhir menjelaskan peran setiap berkas.

Tabel 4.1 Sumber data

Berkas	Baris terverifikasi	Kolom terverifikasi	Fungsi
DataCoSupplyChainDataset.csv	180.519	53	Transaksi tingkat item
tokenized_access_logs.csv	469.977	8	Catatan kunjungan
DescriptionDataCoSupplyChain.csv	52	2	Kamus data

Data sumber memuat 180.519 Order Item Id (identitas satu barang dalam pesanan) yang unik dan 65.752 Order Id (identitas satu nomor pesanan) yang unik. Rata-rata jumlah barang per pesanan dihitung pada Persamaan (4.1). Cakupan nonbatal memuat 62.897 pesanan. Ada satu temuan penting di sini: dalam satu Order Id, semua barang memiliki tanggal pesanan, tanggal pengiriman, dan status keterlambatan yang sama. Karena itu keterlambatan cukup dinilai sekali untuk setiap pesanan, dan tidak perlu dihitung ulang per barang.

$$\mu = \frac{180.519}{65.752} \approx 2{,}75 \ \ item/pesanan \qquad (4.1)$$

Clickstream memiliki kolom Product, Category, Date, Month, Hour, Department, ip, dan url. Pemeriksaan memperoleh 469.977 baris, tidak ada sel kosong, dan 3.249 baris identik penuh. Aturan yang dipertimbangkan adalah menghapus baris yang identik penuh, yaitu menghapus 3.249 baris kembar tersebut. Aturan itu belum dijalankan karena dua kunjungan yang berbeda dapat menghasilkan isi baris yang sama, sehingga kemiripan baris belum cukup untuk memastikan keduanya kejadian yang sama. Angka 466.728 hanya jumlah baris yang akan tersisa jika aturan penghapusan itu diterapkan.

4.1.1 Pembersihan Data Transaksi

Pembersihan dimulai dari 180.519 baris tingkat barang, yaitu satu baris mewakili satu barang dalam satu pesanan, pada 53 kolom transaksi. Lima nama kolom diganti dengan sebutan yang lebih ringkas dipakai program, seperti ditunjukkan pada Tabel 4.2, agar seluruh pengolahan memakai satu nama yang sama. Nama baru itu sebutan teknis internal dan tidak mengubah makna kolomnya. Tanggal dikonversi saat pemrosesan ke format standar internasional (ISO 8601, misalnya 2017-10-01) dan disimpan dalam bentuk itu pada berkas keluaran; berkas CSV sendiri menyimpan semua isi sebagai teks, sehingga tipe data tanggal dikenali saat program membaca berkas, bukan oleh berkasnya.

Tabel 4.2 Pemetaan nama kolom

Kolom sumber	Nama keluaran	Catatan
order date (DateOrders)	order_date	Tanggal pesanan
shipping date (DateOrders)	shipping_date	Tanggal pengiriman; bukan fitur prediksi
Days for shipping (real)	dispatch_real_days	Alias teknis durasi aktual; definisi mengikuti sumber
Days for shipment (scheduled)	dispatch_scheduled_days	Alias teknis durasi terjadwal; definisi mengikuti sumber
Late_delivery_risk	is_late	Label sumber tidak didefinisikan ulang

Tidak ditemukan duplikat baris penuh pada data transaksi. Product Description kosong pada seluruh 180.519 baris. Penghapusan Customer Email, Customer Password, Product Description, dan Product Image menyisakan 49 kolom sumber sebelum penambahan late_days.

Kolom late_days dihitung sebagai selisih antara durasi pengiriman aktual dan durasi yang dijadwalkan, dalam satuan hari, sesuai Persamaan (4.2). Ilustrasi perhitungannya (bukan data penelitian): bila sebuah barang dijadwalkan tiba dalam 3 hari tetapi aktualnya 5 hari, late_days bernilai 2 hari. Penambahan kolom ini menghasilkan 50 kolom. Label is_late tetap nama lain dari Late_delivery_risk pada data sumber, dan definisinya tidak kami ubah. Pada seluruh item nonbatal, is_late konsisten dengan kondisi durasi aktual yang melebihi durasi terjadwal. Kolom late_days dibuat hanya untuk pemeriksaan itu; late_days maupun durasi aktual tidak dipakai sebagai masukan model karena keduanya baru diketahui setelah pengiriman terjadi.

$$d_{late} = d_{actual} - d_{scheduled} \qquad (4.2)$$

Data transaksi bersih berisi 180.519 baris dan 50 kolom, dengan satu baris mewakili satu barang dalam satu pesanan. Setelah 7.754 item dengan Delivery Status = Shipping canceled (dibatalkan) dikeluarkan, data nonbatal memuat 172.765 baris dan 50 kolom. Kolom status akhir dipakai hanya untuk menentukan pesanan mana yang masuk cakupan penelitian, dan tidak pernah menjadi masukan model. Karena cakupan ditentukan dari informasi akhir seperti itu, hasil penelitian ini menggambarkan pesanan yang secara historis diketahui tidak dibatalkan, dan belum tentu berlaku sama untuk pesanan baru yang statusnya belum diketahui.

Tabel 4.3 Tahapan pembersihan transaksi

Tahap	Baris terverifikasi	Kolom	Perubahan
Sumber	180.519	53	CSV sumber
Penghapusan empat kolom	180.519	49	Empat kolom dihapus
Penambahan late_days	180.519	50	Satu kolom late_days ditambahkan
Cakupan nonbatal	172.765	50	7.754 item batal dikeluarkan

4.1.2 Organisasi Data

Data diorganisasi menjadi tiga lapisan agar jejak pengolahan jelas: mentah, bersih, dan siap analitik. Lapisan mentah menyimpan CSV sumber. Lapisan bersih menyimpan transaksi hasil pembersihan serta cakupan nonbatal. Lapisan siap analitik memuat data per pesanan, pembagian temporal, representasi fitur, model, dan hasil evaluasi. Seluruh lapisan berada pada penyimpanan lokal satu komputer. HDFS, yaitu sistem penyimpanan terdistribusi untuk data besar, hanya diuji dengan berkas sederhana, sehingga penelitian ini belum membuktikan pemrosesan dataset penuh secara terdistribusi.

Tabel 4.4 Organisasi data

Lapisan	Isi	Lokasi/status
Mentah	Tiga CSV dan hash acuan SHA-256	Direktori lokal; integritas diperiksa
Bersih	Transaksi bersih dan transaksi nonbatal	Direktori lokal; masing-masing 50 kolom
Siap analitik	Data pesanan, fitur, label, pembagian data, model, dan prediksi	Penyimpanan lokal
HDFS	Berkas pengujian sederhana	Uji tulis/baca; bukan penyimpanan dataset lengkap

4.2 Model Data dan Operasi Data

Unit observasi, prediksi, dan evaluasi adalah pesanan, dengan satu baris untuk setiap Order Id. Artinya, 172.765 baris barang diringkas menjadi 62.897 baris pesanan. Ilustrasinya (bukan data penelitian): satu pesanan yang berisi lima barang diwakili satu baris, bukan lima baris. Sebelum penggabungan itu, konsistensi target, jadwal pengiriman, segmen pelanggan, market, dan tanggal diperiksa di dalam setiap pesanan, dan tidak ditemukan nilai yang bertentangan. Kategori produk dibentuk sebagai himpunan Category Id unik pada pesanan tersebut, sedangkan jumlah item dihitung dari Order Item Id yang unik. Penggabungan ini mencegah satu pesanan dihitung berulang sebagai beberapa observasi model, yang akan membuat jumlah data tampak lebih besar daripada jumlah kejadian sebenarnya.

Rancangan awal pada Assignment I memuat cara menggabungkan skor barang menjadi skor pesanan dengan mengambil nilai tertinggi, sebagaimana ditunjukkan pada Persamaan (4.3). Persamaan ini dicantumkan sebagai catatan riwayat rancangan, bukan bagian dari eksperimen ini. Pada persamaan tersebut, R_o adalah skor pesanan o, I_o adalah himpunan item pada pesanan o, dan r_i adalah skor item i. Implementasi Assignment II langsung menghasilkan probabilitas tingkat pesanan, sehingga cara penggabungan dengan nilai maksimum itu tidak digunakan.

$$R_o = \max_{i \in I_o} r_i \qquad (4.3)$$

Persamaan (4.4) menggambarkan rancangan lama untuk menyatukan clickstream dalam jendela 24 jam sebelum pesanan dibuat, dan juga berlaku sebagai catatan riwayat Assignment I. Simbol t_order menyatakan waktu pesanan dan t_event menyatakan waktu kejadian clickstream; batas awal 24 jam disertakan dan waktu pesanan itu sendiri dikecualikan. Rancangan ini tidak dijalankan, sehingga tidak ada fitur clickstream yang dihasilkan pada Assignment II.

$$t_{order} - 24\ h \leq t_{event} < t_{order} \qquad (4.4)$$

Clickstream tidak disertakan karena kecocokan antara catatan kunjungan dan catatan transaksi belum dapat dibuktikan, begitu pula ketersediaan waktunya. Data kunjungan tidak memuat Order Id, sehingga tidak ada cara langsung untuk mengetahui kunjungan mana yang berujung pada satu pesanan tertentu. Batas ini tidak berarti clickstream tidak berguna; batas ini menahan eksperimen pada data transaksi yang memang dapat dikelompokkan menurut Order Id. Analisis graf pada Bab 6 juga memakai relasi dari data transaksi.

Tabel 4.5 Peran variabel

Kelompok	Contoh	Peran dan batas
Kandidat informasi sebelum pengiriman	Tepat lima kelompok: jadwal, segmen, *market*, kategori *multi-hot*, jumlah ID item unik	*Encoding* dipelajari dari *training*; ketersediaan tepat pada waktu operasional belum terbukti
Label	Late_delivery_risk / is_late	Target sumber; bukan prediktor dan bukan bukti penyerahan kepada kurir
Informasi hasil akhir	Durasi aktual; Delivery Status; shipping_date; late_days	Audit/cakupan; tidak menjadi fitur sebelum pengiriman
Atribut lain dari 50 kolom	Status pesanan, profit, identitas, dan atribut tersisa	Tidak digunakan sebagai fitur; ketersediaan operasional seluruh atribut belum diuji

Durasi aktual, shipping_date, late_days, Delivery Status, dan status akhir tidak digunakan sebagai prediktor. Late_delivery_risk hanya berfungsi sebagai target, sedangkan Order Id sebagai kunci pengelompokan. Representasi model mencakup lima kelompok fitur, dengan daftar kategori encoding dipelajari hanya dari data training. Alasan kolom-kolom hasil akhir dikeluarkan adalah kebocoran informasi (data leakage), yaitu masuknya petunjuk yang sebenarnya baru diketahui setelah peristiwa yang ingin diprediksi. Ilustrasinya (bukan data penelitian): bila model diberi tahu lama pengiriman aktual, model hanya mengulang jawaban yang sudah tersedia pada data, bukan mempelajari pola yang berguna. Pencegahan kebocoran ini tetap belum cukup untuk membuktikan bahwa seluruh fitur memang tersedia pada saat prediksi dilakukan di dunia nyata. Pembahasan kebocoran informasi mengacu pada Kaufman et al. (2012) dan Kapoor dan Narayanan (2023).

Tabel 4.6 Model dan operasi data

Sumber/keluaran	Unit/model	Operasi	Status
Transaksi	Tabular/item	Pemetaan, tanggal, empat kolom, late_days, nonbatal	Dijalankan menggunakan Python lokal
Clickstream	Tabular/kunjungan	Struktur, *timestamp*, kosong, identik penuh	Pemeriksaan selesai; IP tetap pada sumber; deduplikasi tidak diterapkan
Integrasi	Agregat waktu/produk	Jendela 24 jam pra-pesanan	Desain historis Assignment I; tidak dipakai Assignment II
Prioritas	Order Id	Model langsung per pesanan	Model langsung per pesanan telah dilatih dan dievaluasi; penggunaan prioritas operasional belum diuji
Aliran masa depan	Kejadian berkelanjutan	Structured *Streaming*	Rancangan; tidak diuji

Operasi pada Tabel 4.6 adalah prototipe yang dijalankan dengan Python lokal pada mesin pengembang untuk memeriksa struktur data dan pemetaan kolom. Pembersihan final yang menghasilkan 172.765

item dan 62.897 pesanan dijalankan di runtime Google Colab langsung dari CSV mentah, sebagaimana tercatat pada bukti eksekusi: berkas masukan DataCoSupplyChainDataset.csv berukuran 95.910.149 byte beserta angka kohort yang sama dihitung di lingkungan tersebut. Kedua keterangan merujuk tahap yang berbeda, yaitu prototipe lokal dan eksekusi final, sehingga tidak ada pertentangan antara Tabel 4.6 dan Bab 5.

Dataset tingkat pesanan pada bagian 4.3 menjadi dasar pengembangan model pada Bab 5 dan graf pesanan dan kategori pada Bab 6.

4.3 Dataset untuk Diolah Menggunakan *Machine Learning*

Data utama penelitian adalah DataCoSupplyChainDataset.csv versi 5. Berkas DescriptionDataCoSupplyChain.csv, yang memuat keterangan arti setiap kolom, dipakai untuk memeriksa definisi variabel. Data clickstream tidak digunakan dalam model maupun dalam penggabungan fitur. Cakupan penelitian mengecualikan pesanan berstatus Delivery Status = Shipping canceled (dibatalkan). Kolom status itu hanya dipakai untuk memilih dan memeriksa populasi, bukan sebagai prediktor.

Pengelompokan menghasilkan 62.897 pesanan nonbatal dari 172.765 item. Sebanyak 2.855 pesanan yang mencakup 7.754 item dikeluarkan karena memuat barang yang dibatalkan. Tidak ditemukan pesanan yang memuat campuran barang batal dan nonbatal. Dari 62.897 pesanan itu, 36.048 berlabel 1 (terlambat) dan 26.849 berlabel 0 (tidak terlambat). Angka inilah yang menjadi jumlah data penelitian, dan jumlahnya mengikuti jumlah pesanan, bukan jumlah barang. Tabel 4.7 merangkum alur angka ini dari transaksi sumber hingga unit model.

Prediksi ditujukan pada tahap setelah pesanan lolos pemeriksaan pembatalan dan siap memasuki pengiriman, tetapi sebelum barang dikirim. Data historis tidak mencatat kapan setiap informasi, misalnya segmen pelanggan atau daftar kategori barang, mulai diketahui, sehingga kami tidak dapat memastikan semua fitur sudah tersedia pada saat itu. Karena pemilihan data juga memakai status akhir pesanan, penilaian ini bersifat retrospektif: hasil akhir pesanan sudah diketahui saat penilaian dilakukan, sehingga yang diuji adalah data masa lalu yang lengkap, dan belum merupakan pengujian sistem untuk memprediksi pesanan baru secara langsung.

Tabel 4.7 Cakupan dataset Assignment II

Pemeriksaan	Hasil
Transaksi sumber	180.519 item; 65.752 pesanan
Cakupan dipertahankan	172.765 item; 62.897 pesanan
Dikeluarkan	7.754 item; 2.855 pesanan
Pesanan campuran batal/nonbatal	0
Target tingkat pesanan	0 = 26.849; 1 = 36.048
Unit model	Satu observasi per Order Id; 48 dimensi aktual

BAB 5. *MACHINE LEARNING*

5.1 Data *Preprocessing*

Tahap prapengolahan (preprocessing) menyiapkan data mentah menjadi bentuk yang dapat diolah model. Tahap ini dimulai dengan membaca transaksi, mengeluarkan barang berstatus Shipping canceled, lalu memeriksa apakah label dan atribut lain konsisten di dalam setiap Order Id. Setelah itu data digabung pada tingkat pesanan dan dibagi menurut urutan waktu. Data tingkat barang tidak langsung dipakai sebagai masukan model karena satu pesanan dapat memuat beberapa barang, sehingga satu pesanan akan muncul berkali-kali.

Integritas ketiga CSV pada eksperimen diperiksa. Data sumber memuat 180.519 item dalam 65.752 pesanan. Pada cakupan yang dipertahankan, tidak ditemukan konflik target, konflik atribut bernilai tunggal dalam pesanan, maupun kategori kosong. Tidak adanya konflik ini penting karena penggabungan data per pesanan mengandaikan setiap pesanan hanya memiliki satu nilai untuk target dan untuk atribut seperti jadwal, segmen, dan market.

Model hanya dapat mengolah angka, sehingga setiap kategori diubah menjadi deretan angka 0 dan 1 dalam proses yang disebut encoding. Daftar kategori yang dipakai dipelajari hanya dari data training. Customer Segment dan Market memakai one-hot encoding, artinya tersedia satu kolom khusus yang bernilai 1 untuk satu kategori dan 0 untuk kategori lainnya. Ilustrasinya (bukan data penelitian): pelanggan dengan segmen Consumer diwakili angka 1 pada kolom Consumer dan 0 pada kolom segmen lain.

Karena satu pesanan dapat memuat beberapa kategori produk, himpunan Category Id memakai multi-hot encoding sehingga beberapa kolom kategori boleh bernilai 1 sekaligus dalam satu pesanan. MISSING mewakili kategori kosong dan UNKNOWN mewakili kategori yang tidak muncul pada training; kedua penanda ini dibuat agar model tidak menebak nilai yang belum pernah dilihatnya.

Dua fitur numerik memakai satuan asli, tanpa penskalaan atau transformasi logaritmik. Nilai numerik atau identitas wajib yang kosong atau tidak berhingga menyebabkan pengolahan dihentikan, bukan ditebak. Seluruh aturan perubahan yang dipelajari dari data training diterapkan apa adanya pada validation dan test tanpa dipelajari ulang, agar model tidak melihat data uji saat belajar.

Secara teknis, kolom MISSING tidak pernah aktif di seluruh dataset karena tidak ada Category Id yang kosong pada kohort non-batal. Sementara itu, kolom UNKNOWN aktif pada 99,1% pesanan di data test karena 19 dari 51 kategori merupakan jenis baru yang tidak terlihat pada data training. Karena kategori yang tidak ditemukan dalam training tidak memiliki koefisien pengaruh yang dipelajari model (koefisien bobot UNKNOWN bernilai nol), kemampuan model dalam menangani kategori baru masih terbatas. Perlu dicatat, aktifnya kolom UNKNOWN tidak berarti seluruh prediksi kehilangan dasar: kategori yang sudah dikenal pada data training serta fitur lain (jadwal pengiriman, segmen pelanggan, market, dan jumlah item) tetap memberikan kontribusi pada skor, sehingga skor tetap terbentuk, tetapi skor tidak dapat menjelaskan pengaruh kategori baru secara spesifik. Pengelompokan kategori langka ke dalam kategori tunggal OTHER direkomendasikan untuk pengembangan berikutnya. Rincian kuantitatifnya: 19 kategori baru tersebut adalah Category Id 4 dan 59 sampai 76. Pada data test, 7.972 dari 8.043 pesanan (99,12%) memuat paling sedikit satu kategori baru, dan 7.964 di antaranya hanya memuat kategori baru; pada validation hanya 54 pesanan (1,07%), dan pada training tidak ada. Skor rata-rata pesanan test yang memuat kategori baru adalah 0,5731 dengan tingkat keterlambatan 0,5773, sedangkan 71 pesanan tanpa kategori baru memiliki skor rata-rata 0,5247 dan tingkat keterlambatan 0,4789. Karena koefisien UNKNOWN bernilai nol, selisih skor tersebut berasal dari fitur lain, bukan dari kategori baru. Teknik OTHER sebagai pengembangan lanjutan harus dibentuk dari aturan training, bukan dari informasi test.

5.2 *Feature Engineering*

Model menggunakan lima kelompok fitur: Days for shipment (scheduled) atau jadwal lama pengiriman yang dijanjikan, Customer Segment (segmen pelanggan), Market (wilayah pemasaran), Category Id dengan multi-hot encoding, dan jumlah Order Item Id unik per pesanan. Jadwal pengiriman menggambarkan waktu yang dijanjikan, segmen pelanggan dan market menggambarkan konteks pesanan, kategori menggambarkan komposisi produk, sedangkan jumlah item menggambarkan banyaknya jenis barang dalam pesanan. Kelima kelompok ini dipilih karena secara konseptual relevan untuk memperkirakan risiko keterlambatan: jadwal menentukan target waktu, segmen dan market mencerminkan karakteristik pelanggan, kategori menunjukkan jenis produk, dan jumlah item mengindikasikan kompleksitas pesanan. Jumlah item menggambarkan banyaknya baris item pesanan unik (unique order line items), bukan jumlah SKU (nomor identitas jenis barang)/jenis produk maupun total kuantitas barang; satu produk yang sama pada dua baris item tetap dihitung dua. Quantity, atribut keuangan, dan turunannya tidak digunakan.

Days for shipping (real), dispatch_real_days, shipping_date, late_days, Delivery Status, dan status akhir lain tidak dimasukkan karena berkaitan dengan hasil pengiriman yang baru diketahui setelah kejadian. Late_delivery_risk/is_late digunakan hanya sebagai target yang ingin diprediksi. Order Id merupakan identitas pesanan, bukan angka yang mengukur sesuatu. Pemisahan peran variabel tersebut bertujuan menutup kebocoran informasi ke dalam prediktor, sebagaimana dijelaskan pada bagian 4.2. Pemisahan itu tetap belum membuktikan ketersediaan fitur pada waktu operasional, sehingga pembuktiannya memerlukan data tambahan (Kaufman et al., 2012; Kapoor & Narayanan, 2023).

Tabel 5.1 Fitur dan representasi masukan model

Komponen	**Representasi yang digunakan**
Unit dan target	Order Id; Late_delivery_risk
Lima kelompok fitur	Jadwal; segmen; *market*; Category Id *multi-hot*; jumlah Order Item Id unik
Quantity dan keuangan	Tidak diaktifkan, termasuk turunannya
Statistik transformasi	*Vocabulary* hanya *fit* pada *training*; MISSING dan UNKNOWN
Matriks input final	49.826 × 48; 5.028 × 48; 8.043 × 48; tanpa *scaling*/log

Encoding menghasilkan 48 kolom masukan, yang dalam laporan ini disebut juga 48 dimensi: 2 kolom angka, 5 kolom Customer Segment, 7 kolom Market, dan 34 kolom Category Id. Kolom kategori itu sudah mencakup kedua penanda khusus (MISSING dan UNKNOWN), sebagaimana dijelaskan pada bagian 5.1. Jadi matriks training berukuran 49.826 baris pesanan × 48 kolom, validation 5.028 × 48, dan test 8.043 × 48. Tabel 5.1 merangkum susunan masukan ini dan dibaca sebagai daftar komponen, bukan sebagai hasil evaluasi.

5.3 Algoritma

Penelitian menerapkan Logistic Regression (regresi logistik), yaitu model yang memperkirakan peluang sebuah pesanan termasuk kelas terlambat. Keluarannya berupa nilai peluang yang dapat diurutkan dari tertinggi ke terendah. Implementasinya dibuat dua kali dengan dua perangkat lunak berbeda, scikit-learn (Pedregosa et al., 2011) dan Spark MLlib (Meng et al., 2016), memakai parameter tetap sebagaimana tercantum pada Tabel 5.2. Kedua implementasi memakai regularisasi L2, yaitu pengaman agar model tidak terlalu menghafal data latih, tanpa pembobotan kelas, penyeimbangan ulang data (resampling), atau pencarian parameter otomatis. Parameter random_state=42 dicatat dalam konfigurasi, tetapi tidak memengaruhi proses optimasi karena implementasi scikit-learn menggunakan solver lbfgs; parameter itu hanya berlaku untuk solver sag, saga, dan liblinear. Reproduktibilitas eksperimen didukung melalui pencatatan versi perangkat lunak, konfigurasi model, data, dan kode pengolahan. Baseline adalah pembanding paling sederhana: model ini tidak melihat data pesanan sama sekali, melainkan menebak memakai proporsi kelas positif pada data training sebagai probabilitas konstan.

Tabel 5.2 Parameter Logistic Regression

Implementasi	Parameter
scikit-learn	C=1,0; solver=lbfgs; max_iter=1000; tol=0,000001; random_state=42 (tidak berpengaruh pada lbfgs); class_weight=None
Spark MLlib	regParam=0,1; elasticNetParam=0,0; maxIter=1000; tol=0,000001; standardization=False
Hubungan parameter	Tidak dinyatakan ekuivalen; dibandingkan sebagai konfigurasi primer terpisah
Model tambahan	Random Forest dan Gradient Boosting bersifat eksploratori dan dikeluarkan dari run final
Refit	Tidak melatih ulang menggunakan gabungan training dan validation

Parameter diterapkan tanpa penyetelan otomatis (tuning). scikit-learn menggunakan C=1,0, sedangkan Spark MLlib menggunakan regParam=0,1. Kedua angka itu menuliskan kekuatan pengaman regularisasi dengan cara dan skala yang berbeda, sehingga nilainya tidak dapat dibandingkan langsung; karena itu, keduanya tidak dinyatakan ekuivalen. Perbandingan hasil diperlakukan sebagai perbandingan dua implementasi primer yang terpisah. Bagi pembaca, batas ini berarti selisih angka antara kedua implementasi tidak dapat dibaca sebagai bukti bahwa salah satu perangkat lunak lebih baik.

5.4 Proses Pengembangan Model dengan dan tanpa Spark MLlib

Data dibagi menurut urutan tanggal pesanan (order_date), bukan secara acak: training sebelum 1 Juli 2017, validation dari 1 Juli hingga sebelum 1 Oktober 2017, dan test mulai 1 Oktober 2017. Pembagian seperti ini meniru situasi nyata karena model dilatih dari pesanan lama lalu diuji pada pesanan yang lebih baru. Bila data dibagi acak, model berpotensi belajar dari pesanan yang sebenarnya terjadi setelah pesanan yang diuji, sehingga hasilnya tampak lebih baik daripada kenyataan. Setiap Order Id hanya berada dalam satu bagian, sehingga satu pesanan tidak muncul di dua bagian sekaligus. Pembagian tidak menggunakan konversi zona waktu atau jeda antarbagiannya. order_date dipakai sebagai perkiraan urutan waktu (proksi kronologi) karena waktu ketika label akhir tersedia tidak diketahui. Label akhir hanya terisi setelah proses pengiriman selesai, dan dataset 53 kolom itu tidak memuat kolom waktu kapan status tersebut dicatat. Data test tidak digunakan untuk pemilihan parameter atau ambang klasifikasi.

Pembagian ini meniru situasi nyata: training (data untuk mengajari model mengenali pola dari pesanan lama), validation (data untuk memilih pengaturan dan ambang keputusan), dan test (data untuk memeriksa hasil akhir model yang sudah ditetapkan, tidak digunakan untuk penyetelan).

Tabel 5.3 Pembagian temporal data pesanan

Bagian	Label 0	Label 1	Jumlah
Training	21.302	28.524	49.826
Validation	2.140	2.888	5.028
Test	3.407	4.636	8.043

Tabel 5.3 menunjukkan jumlah dan distribusi label pada setiap bagian data. Setiap observasi memiliki Order Id unik. Kedua implementasi menerima susunan fitur yang sama; probabilitas dari Spark dicocokkan kembali menggunakan Order Id. Model dilatih hanya pada *training*, tanpa pelatihan ulang menggunakan gabungan *training* dan *validation*.

Eksperimen final dijalankan pada Google Colab dengan Python 3.13.16 pada Linux x86_64 dan Spark 4.0.4. Spark dijalankan dengan pengaturan master local[2], artinya komputasi memakai dua thread pemrosesan lokal dalam satu proses di satu mesin (bukan berarti dua prosesor fisik), bukan banyak komputer yang saling terhubung (multi-node). Penyimpanan menggunakan penyimpanan biasa mesin virtual Colab (filesystem lokal), bukan HDFS. Konfigurasi ini mendokumentasikan lingkungan eksekusi, dan bukan bukti skalabilitas multi-node. Seluruh angka yang dilaporkan pada Bab 5 diambil dari eksekusi Colab ini. Sebagai pemeriksaan reproduktibilitas, eksekusi lokal sebelumnya pada 20 Oktober 2026 (Python 3.12.15, scikit-learn 1.9.1, Spark 3.5.9) menghasilkan metrik test yang sama sampai enam angka desimal, tetapi ambang validation scikit-learn berbeda, yaitu 0,307476, dan AP validation scikit-learn juga berbeda sedikit, yaitu 0,744400. Penyebab selisih itu tidak tercatat pada artefak yang tersimpan, sehingga laporan ini tidak menjelaskannya dan tetap memakai angka eksekusi Colab. Versi library lain pada eksekusi Colab tidak tercatat dalam bukti eksekusi. Sebagai pembanding, eksekusi lokal 20 Oktober 2026 mencatat Python 3.12.15, scikit-learn 1.9.1, PySpark 3.5.9, NetworkX 3.7, NumPy 2.5.4, pandas 3.0.6, SciPy 1.18.1, matplotlib 3.11.2, dan Java 17.0.20.1 pada macOS 27.0.1.

Eksekusi final menghasilkan model, probabilitas, prediksi, ambang validation, metrik, dan statistik graf. Data utama berukuran 95.910.149 byte (sekitar 91,5 MiB) Seluruh pelatihan, eksekusi Spark, dan komputasi graf dilakukan pada Google Colab; benchmark waktu dan skalabilitas multi-node tidak dilakukan. Berkas pendukung eksperimen tersimpan bersama laporan ini, meliputi skrip pengolahan, keluaran JSON metrik, berkas prediksi per model, dan daftar checksum berkas pada SHA256SUMS.txt di direktori analisis-lanjutan/.

Tabel 5.4 menegaskan bahwa konfigurasi scikit-learn C=1,0 dan Spark regParam=0,1 merupakan dua konfigurasi final terpisah. Hasil keduanya dibandingkan pada pembagian data dan representasi fitur yang sama, tanpa klaim kesetaraan parameter.

Tabel 5.4 Konfigurasi final dua implementasi Logistic Regression

Implementasi	Konfigurasi final	Status perbandingan	Batas klaim
scikit-learn	C=1,0	Primer	Tidak ekuivalen dengan regParam Spark
Spark MLlib	regParam=0,1	Primer	Hasil dibandingkan secara deskriptif

Perbedaan kecil pada AP dan ROC-AUC dibaca sebagai hasil deskriptif dari dua implementasi dengan regularisasi berbeda. Penelitian ini tidak melakukan uji inferensial untuk menyatakan salah satu implementasi unggul.

5.5 Evaluasi Model

Bagian ini menjelaskan ukuran yang dipakai menilai model. Empat hitungan berikut dihitung dari keputusan model pada satu ambang: true positive (TP) berarti pesanan benar-benar terlambat dan ditandai berisiko; false positive (FP) berarti pesanan sebenarnya tidak terlambat tetapi ditandai berisiko; false negative (FN) berarti pesanan terlambat tetapi tidak ditandai; true negative (TN) berarti pesanan tidak terlambat dan tidak ditandai.

Dari hitungan itu, precision adalah TP/(TP+FP), yaitu dari yang ditandai berisiko berapa bagian yang benar; recall adalah TP/(TP+FN), yaitu dari yang benar-benar terlambat berapa bagian yang berhasil ditandai; dan binary F1 adalah 2TP/(2TP+FP+FN) untuk kelas 1, bukan weighted F1, yaitu gabungan precision dan recall. Confusion matrix, yaitu tabel silang antara prediksi dan kenyataan yang keempat kotaknya berisi TN, FP, FN, dan TP, disajikan berurutan true negative (TN), false positive (FP), false negative (FN), true positive (TP). Untuk precision, recall, dan F1, perhitungan memakai parameter zero_division=0, yaitu kesepakatan bahwa hasil yang tidak terdefinisi akibat pembagian dengan nol ditetapkan menjadi nol.

Dua ukuran lain menilai kualitas urutan skor tanpa bergantung pada satu ambang. Average Precision (AP), dihitung dengan average_precision_score, merupakan metrik utama pemeringkatan kelas positif terlambat (label 1). AP merangkum precision dengan pembobotan kenaikan recall dan menilai seberapa baik model menempatkan pesanan berisiko pada posisi teratas daftar; AP bukan ROC-AUC, dan bukan pula luas trapesium di bawah kurva precision–recall. Receiver Operating Characteristic Area Under the Curve (ROC-AUC) mengukur pemeringkatan positif terhadap negatif, yaitu seberapa baik model memisahkan pesanan terlambat dari pesanan tidak terlambat pada seluruh nilai ambang.

Ambang klasifikasi adalah batas nilai peluang untuk memutuskan sebuah pesanan ditandai berisiko: bila peluangnya lebih besar daripada atau sama dengan batas itu, pesanan dinyatakan berisiko. Ambang dipilih hanya dari data validation dengan memaksimalkan binary F1 atas probabilitas unik serta satu batas semua-negatif. Jika beberapa kandidat menghasilkan F1 yang sama, dipilih ambang terbesar. Prediksi kelas memakai operator lebih besar daripada atau sama dengan ambang. Ambang dibekukan sebelum prediksi test dihitung, agar penilaian akhir tidak disesuaikan dengan hasil test: baseline 0,572472, scikit-learn 0,307694, dan Spark MLlib 0,446602.

Tabel 5.5 Hasil evaluasi pada data test

Ukuran	Baseline	LR scikit-learn	LR Spark MLlib
Average precision	0,576402	0,736424	0,736851
ROC-AUC	0,500000	0,719782	0,720601
Precision kelas 1	0,576402	0,576402	0,576402
Recall kelas 1	1,000000	1,000000	1,000000
Binary F1	0,731288	0,731288	0,731288
Confusion matrix (TN, FP, FN, TP)	0, 3.407, 0, 4.636	0, 3.407, 0, 4.636	0, 3.407, 0, 4.636
Threshold validation	0,572472	0,307694	0,446602

Cara membaca Tabel 5.5 dan 5.6: setiap kolom adalah satu model dan setiap baris adalah satu ukuran. Dua baris teratas, average precision dan ROC-AUC, menilai kualitas urutan skor dan tidak bergantung pada ambang, sedangkan precision, recall, binary F1, dan confusion matrix mengikuti ambang validation yang sudah dibekukan. Angka precision, recall, dan binary F1 yang sama pada Tabel 5.5 bukan kekeliruan: ambang yang dipakai membuat ketiga model menandai seluruh 8.043 pesanan test sebagai berisiko, sehingga keputusan ketiganya identik. Baris confusion matrix dibaca berurutan TN, FP, FN, TP. Tabel 5.5–5.6 menyajikan hasil deskriptif dengan enam angka desimal. Tidak ada klaim signifikansi inferensial.

Tabel 5.6 Hasil evaluasi pada data validation

Ukuran	Baseline	LR scikit-learn	LR Spark MLlib
Average precision	0,574383	0,744407	0,744407
ROC-AUC	0,500000	0,719207	0,719909
Precision kelas 1	0,574383	0,574383	0,574612
Recall kelas 1	1,000000	1,000000	1,000000
Binary F1	0,729661	0,729661	0,729846
Confusion matrix (TN, FP, FN, TP)	0, 2.140, 0, 2.888	0, 2.140, 0, 2.888	2, 2.138, 0, 2.888
Threshold validation	0,572472	0,307694	0,446602

5.6 Analisis

Pada data test, AP baseline adalah 0,576402. Logistic Regression scikit-learn menghasilkan AP 0,736424 dan ROC-AUC 0,719782, sedangkan Spark MLlib menghasilkan AP 0,736851 dan ROC-AUC 0,720601. Pada validation, AP scikit-learn 0,744407 dan AP Spark 0,744407; ROC-AUC masing-masing 0,719207 dan 0,719909. Selisih tersebut dilaporkan secara deskriptif dan tidak membuktikan keunggulan inferensial.

Pada ambang validation, seluruh 8.043 pesanan test diprediksi sebagai kelas 1 (berisiko terlambat) oleh baseline dan kedua implementasi. Confusion matrix test adalah TN=0, artinya tidak ada pesanan tidak terlambat yang dikenali benar; FP=3.407, artinya 3.407 pesanan tidak terlambat ikut ditandai berisiko; FN=0, artinya tidak ada pesanan terlambat yang terlewat; dan TP=4.636; precision 0,576402, recall 1,000000, dan binary F1 0,731288.

Pada validation, Spark masih mengklasifikasikan dua observasi negatif dengan benar, tetapi aturan ambangnya tetap hampir seluruhnya positif. Karena itu, model menunjukkan kapasitas untuk diuji sebagai alat pemeringkatan prioritas risiko daripada untuk memutuskan ya atau tidak secara otomatis.

Hasil pengujian top-k menunjukkan presisi yang kuat pada ambang batas prioritas. Angka ini dihitung dari skor peluang Logistic Regression scikit-learn (konfigurasi pada Tabel 5.2); Spark MLlib menghasilkan pola yang hampir sama, yaitu 1.088 pesanan dengan precision 0,8061, 1.671 pesanan dengan precision 0,8737, dan 2.488 pesanan dengan precision 0,8533 pada cutoff yang sama.

Pada cutoff persentil 10% dengan seluruh ties disertakan, terpilih 1.091 pesanan atau 13,56% dari 8.043 pesanan test (3,56 poin persentase di atas target 10%), dengan TP=880 dan precision 0,8066. Pada cutoff persentil 20% terpilih 1.674 pesanan atau 20,81% (TP=1.463, precision 0,8740), dan pada cutoff persentil 30% terpilih 2.496 pesanan atau 31,03% (TP=2.128, precision 0,8526). Ketiganya menghasilkan lift, yaitu precision dibagi prevalensi kelas pada data test (0,5764): 1,40 pada cutoff 10%, 1,52 pada cutoff 20%, dan 1,48 pada cutoff 30%.

Selisih cakupan aktual terjadi karena ties, yaitu beberapa pesanan memiliki skor yang sama pada batas persentil, sehingga seluruh pesanan dengan skor batas itu ikut disertakan dan jumlah terpilih tidak dipotong tepat pada 10%, 20%, atau 30% dari 8.043 pesanan. Sebagai gambaran praktis, precision 0,8740 berarti sekitar 87 dari setiap 100 pesanan yang masuk kelompok 20% teratas benar-benar terlambat pada data test. Nilai baseline 0,5764 identik dengan proporsi kelas positif (late delivery) pada data test (4.636 dari 8.043 pesanan).

Tabel 5.7 Ringkasan pengujian top-k pada data test

Cutoff	Implementasi	Pesanan terpilih	Cakupan aktual	True positive	Precision	Lift
10%	scikit-learn	1.091	13,56%	880	0,8066	1,40
10%	Spark MLlib	1.088	13,53%	877	0,8061	1,40
20%	scikit-learn	1.674	20,81%	1.463	0,8740	1,52
20%	Spark MLlib	1.671	20,78%	1.460	0,8737	1,52
30%	scikit-learn	2.496	31,03%	2.128	0,8526	1,48
30%	Spark MLlib	2.488	30,93%	2.123	0,8533	1,48

Kedua implementasi meningkatkan kemampuan pemeringkatan dibandingkan baseline. Pada data test, Average Precision (AP) baseline sebesar 0,576402, sedangkan Logistic Regression scikit-learn dan Spark MLlib masing-masing menghasilkan 0,736424 dan 0,736851, yaitu peningkatan sekitar 0,160. Pada ROC-AUC, baseline menghasilkan 0,500000, sedangkan scikit-learn dan Spark MLlib menghasilkan 0,719782 dan 0,720601. Peningkatan ini belum berarti keputusan klasifikasi pada satu ambang efektif: seluruh pesanan test masih ditandai berisiko, sehingga precision dan recall sama dengan baseline. AP dan ROC-AUC menilai kemampuan mengurutkan pesanan berdasarkan skor risiko, bukan kalibrasi probabilitas absolut. Penentuan ambang operasional memerlukan informasi biaya kesalahan, kapasitas penanganan, serta pengujian prospektif yang tidak tersedia dalam penelitian ini.

Mengapa seluruh 8.043 pesanan test berada di atas ambang perlu dijelaskan secara eksplisit. Ambang dipilih dari validation dengan memaksimalkan binary F1, dan karena pemeringkatan model lemah, kandidat terbaik adalah ambang terendah yang tersedia, yaitu skor validation paling kecil. Pada eksekusi Colab yang menjadi sumber angka final, ambang scikit-learn 0,307694 dan Spark 0,446602, sedangkan skor test terendah dari larik probabilitas eksekusi itu adalah 0,353144 (scikit-learn) dan 0,447808 (Spark), sehingga seluruh 8.043 pesanan test otomatis menjadi positif. Pada eksekusi lokal, ambang scikit-learn 0,307476 sama persis dengan skor validation terendah dan skor test terendah 0,353159,

sehingga kesimpulannya sama; pada Spark, ambang 0,446602 menyisakan dua observasi validation di bawah ambang (TN=2). Dengan demikian, hasil semua-positif pada data test merupakan konsekuensi mekanis dari ambang yang dibekukan, bukan kesalahan implementasi dan bukan hasil pemilihan ambang dari data test.

Tabel 5.8 Distribusi skor peluang: test (Colab dan eksekusi lokal) serta validation (eksekusi lokal 20 Oktober 2026)

Sumber	Implementasi dan bagian	n	Minimum	Median	Maksimum	Skor ≥ ambang
Colab	scikit-learn, test	8.043	0,353144	0,420483	0,914649	8.043 (100,00%)
Colab	Spark MLlib, test	8.043	0,447808	0,453735	0,865002	8.043 (100,00%)
Lokal	scikit-learn, validation	5.028	0,307476	0,426947	0,935811	5.028 (100,00%)
Lokal	Spark MLlib, validation	5.028	0,446311	0,453239	0,865781	5.026 (99,96%)
Lokal	scikit-learn, test	8.043	0,353159	0,420485	0,914649	8.043 (100,00%)
Lokal	Spark MLlib, test	8.043	0,447789	0,453721	0,865100	8.043 (100,00%)

Tabel 5.8 memuat dua sumber yang dibedakan pada kolom pertama. Baris test menggunakan larik probabilitas eksekusi Colab yang menjadi sumber angka final, sedangkan baris validation menggunakan berkas prediksi eksekusi lokal 20 Oktober 2026 karena probabilitas per observasi eksekusi Colab tidak tersimpan sebagai berkas; baris itu berfungsi sebagai pemeriksaan reproduktibilitas, bukan bukti langsung distribusi validation final. Nilai minimum dan maksimum menunjukkan skor prediksi berada pada rentang yang berbeda untuk setiap implementasi, sedangkan median berada pada kisaran 0,42–0,45. Median tersebut berada di bawah proporsi kelas positif pada data test, yaitu sekitar 0,5764. Namun, perbandingan median dan prevalensi kelas belum cukup untuk menentukan apakah probabilitas model telah terkalibrasi. Oleh karena itu, skor probabilitas dalam penelitian ini digunakan untuk mengevaluasi kemampuan pemeringkatan risiko, bukan sebagai estimasi probabilitas absolut yang telah terbukti akurat. Pengujian kalibrasi secara khusus, misalnya menggunakan calibration curve dan Brier score, dapat dilakukan pada penelitian lanjutan.

Angka pada Tabel 5.5 dan 5.6 diuji dalam dua peran yang berbeda. Sebagai bukti provenance, seluruh nilai average precision, ROC-AUC, precision, recall, binary F1, dan confusion matrix pada kedua tabel cocok sampai enam angka desimal dengan evidence-colab-final-2026-10-22.json, sehingga angka yang dilaporkan memang berasal dari eksekusi Colab. Sebagai pemeriksaan metode, berkas prediksi eksekusi lokal (predictions-validation-*.csv dan predictions-test-*.csv) dihitung ulang dengan rumus yang sama dan hasilnya identik dengan metrics.json eksekusi lokal. Eksekusi lokal itu juga mereproduksi AP test dan ROC-AUC test Colab sampai enam angka desimal, tetapi ambang scikit-learn (0,307476 berbanding 0,307694) dan AP validation (0,744400 berbanding 0,744407) berbeda tipis. Karena itu hasil lokal dipakai sebagai pemeriksaan metode dan reproduktibilitas, bukan sebagai sumber angka final.

Model final dibatasi pada Logistic Regression. Random Forest (Breiman, 2001) dan Gradient Boosting (Friedman, 2001), uji tanpa sebagian fitur (ablation), serta variasi representasi jadwal pernah dieksplorasi, tetapi tidak menjadi bagian dari uji utama (run konfirmatori) dan tidak digunakan untuk memilih model utama.

Ketersediaan fitur pada waktu prediksi belum dapat direkonstruksi dari potret data historis (snapshot). Empat kelompok fitur, yaitu jadwal, segmen pelanggan, market, dan kategori, tidak memiliki catatan waktu perubahan, sehingga nilai fitur pada saat prediksi dibuat (as-of) tidak dapat dipastikan. Jumlah Order Item Id unik juga mengandaikan seluruh item pesanan telah diketahui pada saat itu. Oleh sebab itu, hasil penelitian ini hanya mendukung penilaian atas data masa lalu, dan bukan klaim kesiapan sistem untuk dipakai (deployment).

Kesimpulan ini juga terbatas karena tiga hal: data dibatasi pada pesanan yang secara historis tidak dibatalkan, urutan waktu memakai order_date sebagai perkiraan, dan kematangan label tidak diketahui, artinya kami tidak tahu kapan status setiap pesanan benar-benar final. Dataset tidak memuat kolom waktu yang mencatat saat status akhir ditetapkan, sedangkan pengiriman sendiri berlangsung setelah tanggal pesanan. Metrik hanya berlaku kondisional untuk pesanan yang secara retrospektif diketahui tidak dibatalkan. Pengujian untuk penggunaan nyata memerlukan definisi kapan prediksi dilakukan, rekonstruksi nilai fitur pada saat itu, pencatatan waktu ketersediaan label, dan pengujian ke depan yang terpisah.

BAB 6. *GRAPH ANALYTICS*

6.1 Pengembangan Graph

Analisis graf menggunakan graf bipartit yang menghubungkan pesanan dengan kategori produk dari seluruh cakupan historis nonbatal. Graf bipartit memiliki dua jenis node dan hanya menghubungkan node dari jenis yang berbeda. Node diberi awalan order: dan category: agar identitas pesanan dan kategori tidak tertukar. Setiap edge merupakan pasangan unik Order Id–Category Id; graf tidak berarah, tidak berbobot, dan tidak memiliki self-loop atau hubungan node ke dirinya sendiri. Spark DataFrame membentuk edge unik, sedangkan NetworkX (Hagberg et al., 2008) menghitung metrik pada satu mesin. Graf tidak digunakan sebagai fitur model dan tidak merepresentasikan rute pengiriman.

Graf lengkap memuat 62.948 *node*, terdiri atas 62.897 pesanan dan 51 kategori, dengan 152.676 *edge* unik dan 19 *connected components*. *Connected component* adalah kelompok *node* yang saling dapat dijangkau melalui rangkaian *edge*. Tidak ditemukan *self-loop* atau *edge* duplikat. Identitas kategori mengikuti Category Id, bukan penggabungan berdasarkan nama kategori.

Tabel 6.1 Definisi graf pesanan dan kategori

Komponen	Definisi
Node pesanan	Satu Order Id yang dipertahankan pada kohort nonbatal
Node kategori	Satu Category Id yang muncul pada pesanan tersebut
Edge bipartit	Pasangan unik pesanan–kategori tanpa bobot dan tanpa arah
Metrik final	Degree kategori dan connected components

Degree kategori adalah jumlah pesanan unik yang terhubung ke kategori tersebut, bukan jumlah item atau unit barang. Visualisasi menggunakan sepuluh kategori dengan *degree* terbesar; jika *degree* sama, Category Id diurutkan secara numerik menaik. Gabungan pesanan tetangga diurutkan berdasarkan Order Id numerik menaik dan diambil 200 pertama. Posisi *node* ditentukan menggunakan *spring layout* dengan *seed*=42 dan *iterations*=50. Seluruh metrik graf lengkap dihitung sebelum pemilihan subset.

Gambar 6.1 menampilkan subset berisi sepuluh kategori dan 200 pesanan, sehingga terdapat 210 *node* dan 495 *edge*. Hubungan menunjukkan bahwa suatu kategori tercatat dalam pesanan. Posisi visual *node* bukan koordinat geografis. Statistik pada Tabel 6.2–6.3 berasal dari graf lengkap, bukan dari kepadatan visual subset.

Tabel 6.2 *Degree* sepuluh kategori pada graf lengkap

Category Id	***Degree* (pesanan unik)**
17 (Cleats)	19.534
18 (Men's Footwear)	17.954
24 (Women's Apparel)	17.088
46 (Indoor/Outdoor Games)	15.912
45 (Fishing)	14.527
48 (Water Sports)	13.174
43 (Camping & Hiking)	11.787
9 (Cardio Equipment)	10.857
29 (Shop By Sport)	9.700
37 (Electronics)	1.920

Tabel 6.3 Komponen terhubung pada graf lengkap

Komponen	*Node*	Pesanan	Kategori	*Edge*
1	54.966	54.933	33	144.712
2	805	804	1	804
3	632	631	1	631
4	623	622	1	622
5	563	562	1	562
6	508	507	1	507
7	473	472	1	472
8	467	466	1	466
9	460	459	1	459
10	459	458	1	458
11	426	425	1	425
12	418	417	1	417
13	410	409	1	409
14	392	391	1	391
15	347	346	1	346
16	337	336	1	336
17	264	263	1	263
18	199	198	1	198
19	199	198	1	198

Analisis final dibatasi pada rancangan G1 yang dirumuskan pada Assignment I, yaitu graf bipartit pesanan–kategori, degree kategori, dan connected components. Proyeksi kategori, PageRank (Page et al., 1999), eigenvector centrality, betweenness, dan community detection (Blondel et al., 2008) tidak digunakan dalam analisis final.

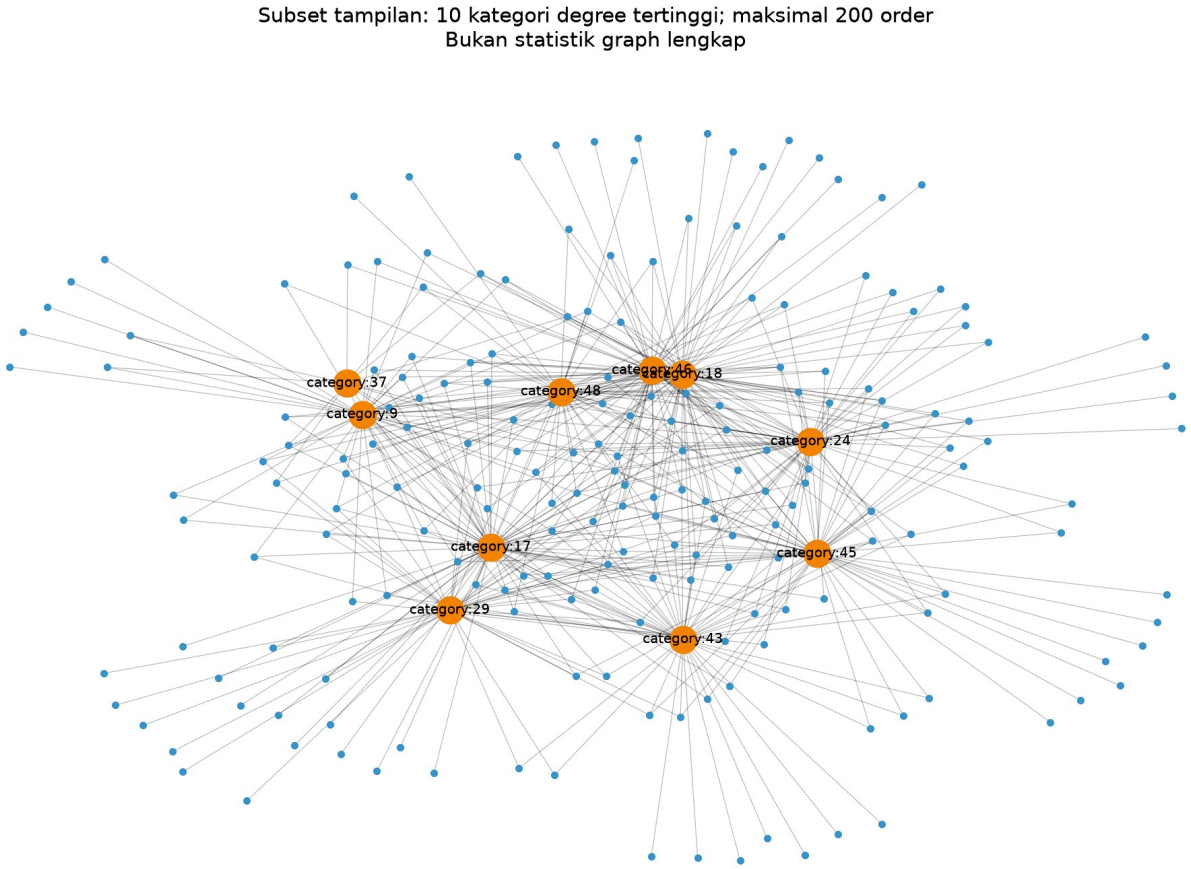
6.2 Analisis dan Insight yang Diperoleh

Graf lengkap terbagi menjadi 19 komponen terhubung. Komponen terbesar memuat 54.966 node, yaitu 54.933 pesanan dan 33 kategori, dengan 144.712 edge. Delapan belas komponen lain masing-masing berisi satu kategori beserta pesanan yang hanya terhubung melalui kategori tersebut. Struktur ini menggambarkan ko-keanggotaan kategori dalam pesanan, bukan wilayah, rute, atau hubungan sebab akibat.

Category Id 17 memiliki degree terbesar, yaitu 19.534 pesanan unik, diikuti Category Id 18 dengan 17.954 dan Category Id 24 dengan 17.088. Degree mengukur jangkauan kategori terhadap pesanan, bukan volume unit barang atau pengaruh kausal terhadap keterlambatan. Interpretasi dibatasi pada struktur graf G1 yang dihitung dari kohort retrospektif nonbatal.

Sepuluh kategori dengan degree tertinggi dipilih dari 51 kategori yang muncul pada graf; pemilihan ini hanya untuk visualisasi dan tidak mengubah statistik graf lengkap. Ketiadaan sinyal pada uji kategori saja, yaitu pengujian tambahan yang hanya memakai Category Id sebagai masukan tanpa satu pun statistik graf (implementasi scikit-learn, C=1,0; AP 0,576577; ROC-AUC 0,5000) konsisten dengan temuan bahwa struktur kategori tidak memisahkan keterlambatan, meskipun tingkat keterlambatan per kategori bervariasi antara 0,4963 dan 0,6885. Variasi tersebut tidak cukup untuk menghasilkan pemeringkatan pesanan yang baik, sehingga metrik graf belum layak dijadikan fitur tanpa pengujian tambahan. Pengujian tersebut bukan evaluasi model prediksi berbasis struktur graf, karena degree, komponen terhubung, dan representasi graf lain tidak dimasukkan sebagai fitur.

Visualisasi subset membantu memperlihatkan dua jenis *node* dan hubungan pesanan dengan kategori, tetapi tidak mencakup seluruh graf. Pemilihan berdasarkan *degree* serta urutan Order Id bukan sampel acak dan tidak membuktikan keterwakilan struktur keseluruhan. Karena itu, jumlah komponen dan *degree* kategori ditafsirkan dari pengukuran graf lengkap, bukan dari posisi atau kepadatan *node* pada Gambar 6.1.



Gambar 6.1 Subset graf pesanan dan kategori: 210 node dan 495 edge (Node biru: pesanan, node oranye: kategori produk, garis penghubung: keberadaan kategori dalam pesanan)

Relasi yang dianalisis menunjukkan kategori apa saja yang tercatat bersama dalam pesanan. Graf tidak memodelkan gudang, kurir, urutan perjalanan, atau waktu tempuh. Hubungan struktur graf dengan label diuji secara deskriptif melalui tingkat keterlambatan per kategori (Tabel 6.4), bukan melalui pengujian kausal dan bukan sebagai fitur model. Denominator total pada Tabel 6.4 (152.676 pasangan pesanan–kategori) mewakili jumlah edge pesanan-kategori, sehingga berbeda dari total 62.897 pesanan unik. Tingkat keterlambatan per kategori berkisar 0,4963 (Category Id 30) sampai 0,6885 (Category Id 34), dengan tingkat keterlambatan seluruh 62.897 pesanan unik sebesar 0,5731. Karena satu pesanan dapat memuat lebih dari satu kategori produk, pesanan yang sama dapat tercatat pada beberapa baris kategori. Oleh karena itu, penjumlahan kolom pesanan terlambat pada seluruh kategori (87.551) tidak menunjukkan jumlah pesanan terlambat yang unik. Uji eksplorasi menggunakan Logistic Regression scikit-learn (C=1,0) pada satu set fitur kategori saja menghasilkan AP 0,576577 dan ROC-AUC 0,5000 — pengujian ini memakai pembagian training/validation/test yang sama dengan eksperimen utama dan implementasi Logistic Regression yang identik. Rentang tersebut menunjukkan variasi antarkategori, tetapi tidak membuktikan bahwa kategori menyebabkan keterlambatan. Nilai ekstrem berasal dari kategori berukuran kecil: Category Id 34 hanya memuat 61 pesanan (0,04% dari 152.676 pasangan), sedangkan Category Id 17 memuat 19.534 pesanan, sehingga perbedaan tingkat keterlambatan bersifat deskriptif dan belum diuji signifikansi statistiknya.

Tabel 6.4 Tingkat keterlambatan per kategori pada graf lengkap

Category Id	Pesanan unik	Pesanan terlambat	Tingkat keterlambatan
2 (Soccer)	134	74	0,5522
3 (Baseball & Softball)	603	347	0,5755
4 (Basketball)	62	35	0,5645
5 (Lacrosse)	327	205	0,6269
6 (Tennis & Racquet)	313	182	0,5815
7 (Hockey)	583	327	0,5609
9 (Cardio Equipment)	10857	6206	0,5716
10 (Strength Training)	109	64	0,5872
11 (Fitness Accessories)	294	174	0,5918
12 (Boxing & MMA)	400	237	0,5925
13 (Electronics)	1057	617	0,5837
16 (As Seen on TV!)	66	39	0,5909
17 (Cleats)	19534	11228	0,5748
18 (Men's Footwear)	17954	10247	0,5707
24 (Women's Apparel)	17088	9723	0,5690
26 (Girls' Apparel)	1128	659	0,5842
29 (Shop By Sport)	9700	5582	0,5755
30 (Men's Golf Clubs)	272	135	0,4963
31 (Women's Golf Clubs)	170	97	0,5706
32 (Golf Apparel)	428	229	0,5350
33 (Golf Shoes)	501	291	0,5808
34 (Golf Bags & Carts)	61	42	0,6885
35 (Golf Gloves)	1023	598	0,5846
36 (Golf Balls)	1373	787	0,5732
37 (Electronics)	1920	1122	0,5844
38 (Kids' Golf Clubs)	348	199	0,5718

Category Id	Pesanan unik	Pesanan terlambat	Tingkat keterlambatan
40 (Accessories)	1670	999	0,5982
41 (Trade-In)	917	534	0,5823
43 (Camping & Hiking)	11787	6719	0,5700
44 (Hunting & Shooting)	420	245	0,5833
45 (Fishing)	14527	8330	0,5734
46 (Indoor/Outdoor Games)	15912	9113	0,5727
48 (Water Sports)	13174	7568	0,5745
59 (Books)	391	229	0,5857
60 (Baby)	198	109	0,5505
61 (CDs)	263	141	0,5361
62 (Cameras)	562	344	0,6121
63 (Children's Clothing)	622	348	0,5595
64 (Computers)	425	224	0,5271
65 (Consumer Electronics)	409	238	0,5819
66 (Crafts)	458	271	0,5917
67 (DVDs)	459	259	0,5643
68 (Garden)	466	270	0,5794
69 (Health and Beauty)	346	202	0,5838
70 (Men's Clothing)	198	113	0,5707
71 (Music)	417	248	0,5947
72 (Pet Supplies)	472	290	0,6144
73 (Sporting Goods)	336	198	0,5893
74 (Toys)	507	291	0,5740
75 (Video Games)	804	455	0,5659
76 (Women's Clothing)	631	367	0,5816

BAB 7. KESIMPULAN DAN REKOMENDASI

Penelitian ini menerapkan analitik data, machine learning, dan graph analytics pada dataset DataCo Supply Chain versi 5. Hasil utama meliputi:

1. Dataset transaksi berhasil dibersihkan dan diorganisasi menjadi 62.897 pesanan nonbatal, dengan 48 dimensi masukan hasil encoding yang mencakup jadwal pengiriman, segmen pelanggan, market, kategori produk, dan jumlah item.

2. Logistic Regression menghasilkan Average Precision (AP) 0,736–0,737 pada data test (peningkatan ≈0,16 dari baseline), dengan kemampuan mengurutkan risiko yang lebih baik daripada kemampuan menentukan keputusan ya/tidak pada satu ambang. Potensi sebagai alat pemeringkatan prioritas ini bersifat retrospektif: ambang klasifikasi belum menghasilkan pemisahan kelas yang berguna, dan penerapan operasional memerlukan pengujian prospektif serta jaminan ketersediaan fitur pada waktu prediksi.

3. Analisis graf bipartit pesanan–kategori mengidentifikasi struktur ko-keanggotaan: 19 komponen terhubung, degree tertinggi pada kategori 17, 18, dan 24, serta variasi tingkat keterlambatan per kategori antara 0,496 dan 0,689.

Batasan utama: penelitian retrospektif menggunakan label akhir yang tidak diketahui waktu penetapannya, ketersediaan fitur pada saat prediksi belum dapat direkonstruksi, dan kolom UNKNOWN aktif pada 99,1% pesanan test karena 19 dari 51 kategori tidak muncul di training. Implementasi pemrosesan menggunakan Apache Spark dalam mode lokal (local[2]) pada satu mesin, sedangkan HDFS hanya diuji melalui operasi dasar baca dan tulis berkas. Oleh karena itu, penelitian ini belum membuktikan skalabilitas pemrosesan terdistribusi maupun kesiapan implementasi streaming dalam lingkungan produksi. Pada ambang klasifikasi yang dipakai, seluruh 8.043 pesanan test ditandai berisiko. Model menunjukkan potensi sebagai alat pemeringkatan prioritas berdasarkan evaluasi retrospektif, tetapi efektivitas penggunaannya dalam proses operasional belum dapat dipastikan dan memerlukan pengujian prospektif.

Pengembangan berikutnya: (a) menguji representasi kategori baru (termasuk teknik OTHER), (b) mengevaluasi model dengan informasi biaya kesalahan dan kapasitas penanganan, (c) membangun jaminan ketersediaan fitur pada waktu prediksi, serta (d) pengujian prospektif dengan pesanan baru.

DAFTAR PUSTAKA

Akturk, M. S., Mallipeddi, R. R., & Jia, X. (2022). Estimating impacts of logistics processes on online customer ratings: Consequences of providing technology-enabled order tracking data to customers. *Journal of Operations Management*, *68*(6–7), 775–811. https://doi.org/10.1002/joom.1204

Apache Software Foundation. (n.d.-a). *HDFS Architecture*. Diakses 20 Oktober 2026, dari https://hadoop.apache.org/docs/current/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html

Apache Software Foundation. (n.d.-b). *Submitting Applications* (Spark 4.0.4 Documentation). Diakses 20 Oktober 2026, dari https://spark.apache.org/docs/4.0.4/submitting-applications.html

Blondel, V. D., Guillaume, J.-L., Lambiotte, R., & Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, *2008*(10), P10008. https://doi.org/10.1088/1742-5468/2008/10/P10008

Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324

Constante, F., Silva, F., & Pereira, A. (2019). *DataCo SMART SUPPLY CHAIN FOR BIG DATA ANALYSIS* (Version 5) [Data set]. Mendeley Data. https://doi.org/10.17632/8gx2fvg2k6.5

European Parliament and Council of the European Union. (2016). Regulation (EU) 2016/679 (General Data Protection Regulation). *Official Journal of the European Union, L 119*, 1–88. https://eur-lex.europa.eu/eli/reg/2016/679/oj

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, *29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Hagberg, A. A., Schult, D. A., & Swart, P. J. (2008). Exploring network structure, dynamics, and function using NetworkX. In G. Varoquaux, T. Vaught, & J. Millman (Eds.), *Proceedings of the 7th Python in Science Conference (SciPy2008)* (pp. 11–15).

Kapoor, S., & Narayanan, A. (2023). Leakage and the reproducibility crisis in machine-learning-based science. *Patterns*, *4*(9), 100804. https://doi.org/10.1016/j.patter.2023.100804

Kaufman, S., Rosset, S., Perlich, C., & Stitelman, O. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, *6*(4), 1–21. https://doi.org/10.1145/2382577.2382579

Meng, X., Bradley, J., Yavuz, B., Sparks, E., Venkataraman, S., Liu, D., Freeman, J., Tsai, D. B., Amde, M., Owen, S., Xin, D., Xin, R., Franklin, M. J., Zadeh, R., Zaharia, M., & Talwalkar, A. (2016). MLlib: Machine learning in Apache Spark. *Journal of Machine Learning Research, 17*(34), 1–7.

Page, L., Brin, S., Motwani, R., & Winograd, T. (1999). *The PageRank citation ranking: Bringing order to the web* (Technical Report No. 1999-66). Stanford InfoLab. http://ilpubs.stanford.edu:8090/422/

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Zaharia, M., Chowdhury, M., Das, T., Dave, A., Ma, J., McCauley, M., Franklin, M. J., Shenker, S., & Stoica, I. (2012). Resilient distributed datasets: A fault-tolerant abstraction for in-memory cluster computing. In *Proceedings of the 9th USENIX Symposium on Networked Systems Design and Implementation* (pp. 15–28). USENIX Association.

BINUS UNIVERSITY ARTIFICIAL INTELLIGENCE USE DECLARATION FORM

Name: Rafael Yudianto

Student ID: 2702752495

Course Code: COMP8035041

Course Title: Big Data Analytics

Assignment Title: COMP8035041 - Personal - Assignment II

Assignment Type: Partial
Type 1 / Type 2 / Type 3 / Type 4 / Type 5: (Pending course-specific definition)

Saya menyatakan menggunakan AI dalam penyelesaian dan persiapan assignment ini.

Perkiraan kontribusi AI pada submission akhir: 40 %

Tempat: Jakarta Tanggal: 30-10-2026

ASSIGNMENT PART	USED AI TOOL?	TOOL(S) USED	KEY PROMPT
Idea and content discussion	Yes	Hermes Agent (AI assistant)	Diskusikan definisi target, unit pesanan, kebocoran informasi, dan batas interpretasi hasil.
Text/Script generation	Yes	Hermes Agent (AI assistant)	Bantu menyusun dan memeriksa kode serta menyunting laporan berdasarkan hasil eksperimen aktual.
Image/Video/Graphics generation	Yes	Hermes Agent (AI assistant)	Buat diagram arsitektur dan alur aktual DataCo; bedakan pipeline lokal, graf, dan uji HDFS.
Translation, grammar, and spelling check	Yes	Hermes Agent (AI assistant)	Perbaiki bahasa Indonesia akademik, konsistensi istilah, dan tata letak laporan.
Others	Yes	Hermes Agent (AI assistant)	Audit metrik dari prediksi tersimpan, statistik graf, sitasi, field Word, dan hasil render.

Tanda tangan mahasiswa: .....
(Rafael Yudianto)