BINUS GRADUATE PROGRAM • MAGISTER TEKNIK INFORMATIKA

# Late Delivery Risk Analysis using Machine Learning & Graph Analytics

Personal Assignment II – COMP8035041 Big Data Analytics

**Disusun oleh: Rafael Yudianto | NIM: 2702752495**

# Latar Belakang & Problem Statement

MARKET & BUSINESS DRIVERS

## Dampak Finansial & Kepuasan Pelanggan

• Keterlambatan pengiriman memicu denda penalti SLA (Service-Level Agreement) dan meningkatkan biaya operasional kompensasi.
• Dalam e-commerce yang kompetitif, kepastian estimasi waktu tiba adalah faktor kunci retensi dan kepuasan pelanggan (customer satisfaction).
• Lebih dari 57% pesanan historis mengalami keterlambatan pengiriman jika tidak diantisipasi secara tepat.

OPERATIONAL CHALLENGES

## Keterbatasan Kapasitas & Bottleneck Gudang

• Volume pesanan harian mencapai puluhan ribu, membuat staf gudang kesulitan memilah order darurat secara manual.
• Ketiadaan sistem peringatan dini (early warning system) mengakibatkan penanganan bersifat reaktif setelah barang terlambat.
• Kategori produk yang sering dipesan bersamaan berpotensi menjadi titik penumpukan antrean pemrosesan di gudang.

RESEARCH OBJECTIVES

## Solusi Big Data & Risk Prioritization

• Membangun pipeline prediktif end-to-end berbasis Apache Spark MLlib untuk memprediksi probabilitas risiko keterlambatan.
• Menghasilkan Risk Prioritization Ranking agar tim logistik memiliki daftar urutan kerja prioritas sebelum pengiriman jalan.
• Menerapkan Graph Analytics untuk memetakan keterhubungan produk dan mendeteksi klaster kategori padat risiko.

# Big Data Architecture & Processing Pipeline

RUNTIME ENVIRONMENT

## Google Colab Environment

Dijalankan pada VM Ubuntu x86_64 dengan Python 3.13, PySpark 3.5, dan OpenJDK 17. Pipeline dieksekusi secara lokal (local[2]) dengan 2 worker threads paralel.

STORAGE & INGESTION

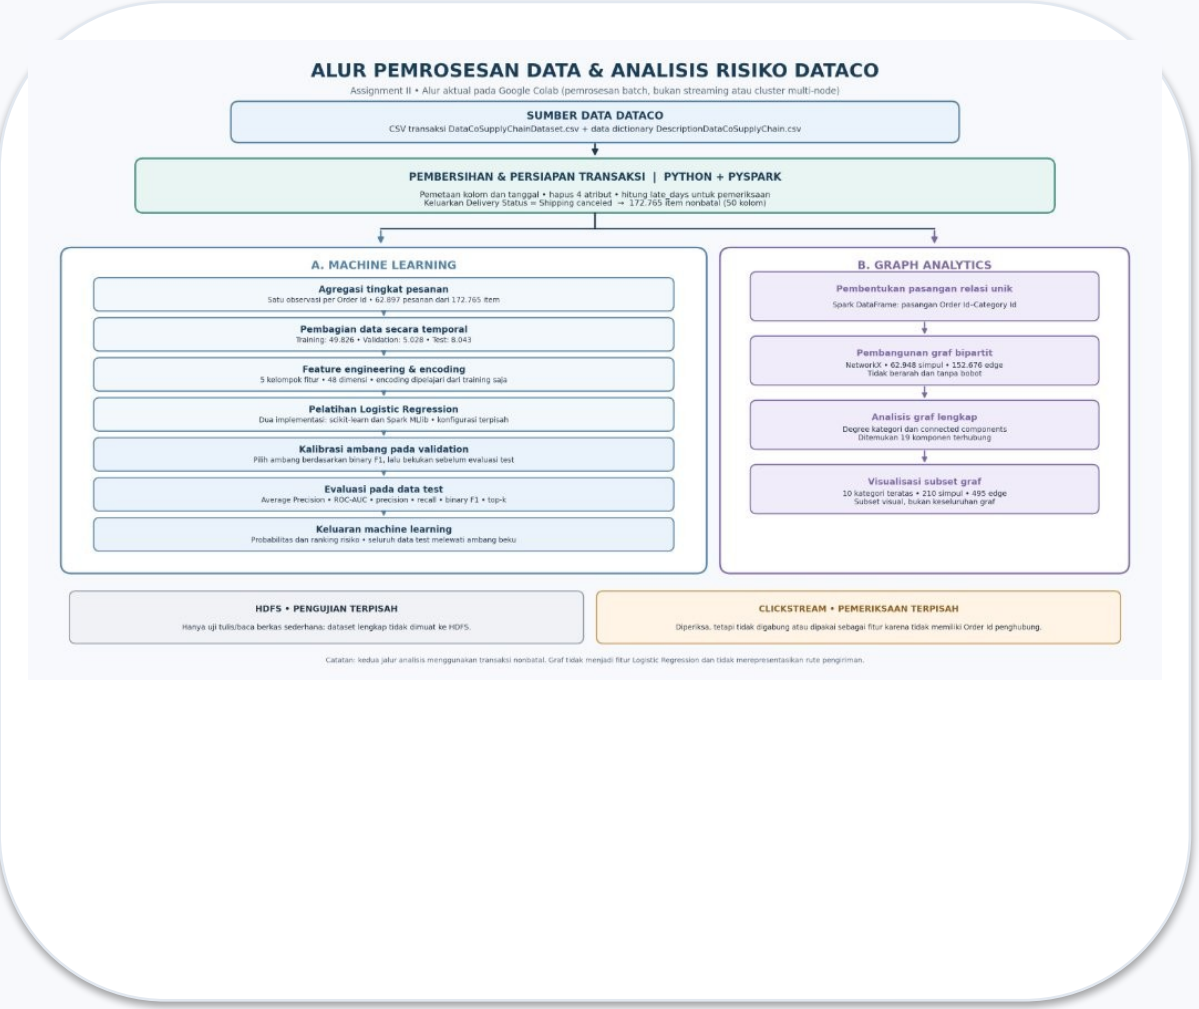
## Hybrid Storage Proof-of-Concept

Batch ingestion dari raw CSV DataCo. HDFS diuji pada single DataNode (smoke test tulis/baca berkas dasar). Data olahan disimpan pada virtual filesystem Colab.

SECURITY & GOVERNANCE

## Data Hygiene & Privacy Framework

Atribut sensitif (Customer Password & Email) langsung di-drop di tahap awal. Lisensi data resmi CC BY 4.0 (Mendeley Data) dengan rujukan prinsip GDPR.



COMP8035041 – BIG DATA ANALYTICS

# Data Preprocessing & Pencegahan Data Leakage

RAW TRANSACTION ITEMS

**180.519**

Baris item mentah mencakup 65.752 unique orders

DROPPED CANCELLED ITEMS

**7.754**

Shipping canceled (4.062 fraud + 3.692 cancel)

CLEAN ORDER OBSERVATIONS

**62.897**

Non-canceled orders (36.048 late, 26.849 on-time)

STRICT DATA LEAKAGE PREVENTION

## Pemisahan Durasi Janji vs Durasi Riil

- Days for shipping (real) & status akhir DIBUANG MUTLAK karena baru diketahui pascapengiriman (post-delivery event).
- Hanya Days for shipment (scheduled) yang sah dipakai sebelum pengiriman.
- Fitur agregasi dihitung per pesanan (Order Id) tanpa membocorkan label.

REALISTIC TEMPORAL DATA SPLITTING

## Pemisahan Kronologis Berdasarkan Waktu

- Training Set (< Juli 2017): 49.826 orders (57,25% late)
- Validation Set (Juli – Okt 2017): 5.028 orders (57,44% late)
- Test Set (≥ Okt 2017): 8.043 orders (57,64% late)

Menghindari Random Split agar meniru situasi produksi: data masa lalu memprediksi pesanan masa depan.

COMP8035041 – BIG DATA ANALYTICS

# Machine Learning Modeling: scikit-learn vs Spark MLlib

AVERAGE PRECISION (AP)

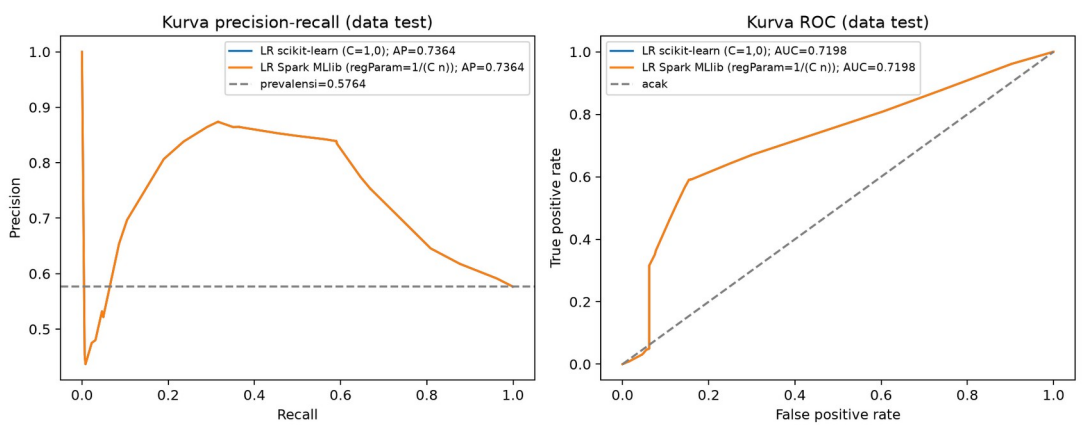
**0,7364**

+16% vs baseline (0,5764)

ROC-AUC SCORE

**0,7242**

Identik scikit-learn & Spark




KEY TAKEAWAY & ABLATION STUDY

## Fitur Penentu: Jadwal Pengiriman (Scheduled)

- Days for shipment (scheduled) secara mandiri menghasilkan AP 0,7249 (hampir menyamai model lengkap 0,7364).
- Tanpa fitur jadwal, performa AP merosot drastis ke 0,5836 (mendekati random baseline 0,5764).
- Model optimal difungsikan sebagai Risk Prioritization Ranking (Top-K Alert harian), bukan pemutus biner kaku.

COMP8035041 – BIG DATA ANALYTICS

# Graph Analytics: Bipartite Network Analysis

GRAPH MODEL & SCALE

## Bipartite Order-Category Network

62.948 total nodes (62.897 orders + 51 categories) dengan 152.676 edges unik. Memetakan co-purchasing pattern secara unweighted & undirected.

CONNECTED COMPONENTS

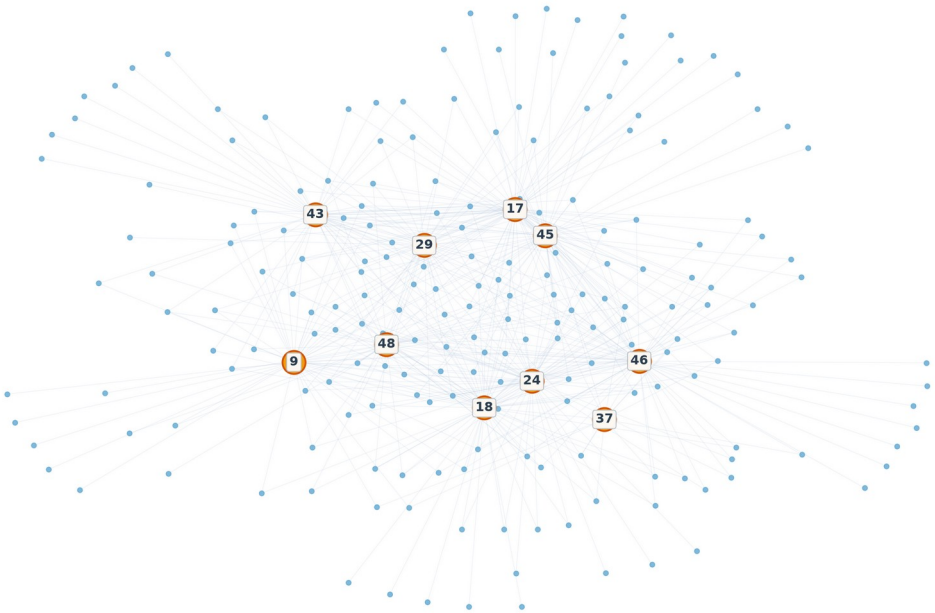
## 19 Komponen Terhubung

54.966 nodes (99,9% order) tergabung dalam 1 Giant Component. 18 komponen lainnya berisi kategori terisolasi dengan pesanan khusus.

HIGH-DEGREE HUBS

## Bottleneck Kategori Kritis

Kategori 17, 18, dan 24 memiliki koneksi pesanan tertinggi (degree hingga 19.534 orders) dengan tingkat keterlambatan di atas rata-rata operasional.



# Limitations & Academic Transparency

EXECUTION SCOPE

## Single-Node PoC Runtime

Spark dijalankan pada mode local[2] di Google Colab. Validasi berfokus pada kelayakan fungsional distributed-ready pipeline, bukan klaim benchmark multi-node cluster fisik.

RETROSPECTIVE NATURE

## Historical Snapshot Filter

Filtering non-canceled orders didasarkan pada status akhir pengiriman historis, bukan dynamic real-time filter sebelum barang jalan di lini produksi.

EXTREME CATEGORY DRIFT

## 99% Unseen Categories in Test

Sebanyak 7.972 dari 8.043 pesanan test memuat kategori baru yang tidak ada di training set. Namun model tidak collapse karena stabilitas ranking ditopang jadwal pengiriman.

SCORE CONCENTRATION

## Optimal for Ranking, Not Cutoff

Distribusi probabilitas pada test set terkonsentrasi di atas 0,50. Penggunaan terbaik adalah sebagai decision support untuk Risk Ranking, bukan otomasi biner kaku.

# Conclusion & Future Recommendations

## KEY RESEARCH CONCLUSIONS

### 1. End-to-End Pipeline & Zero Leakage

Unit observasi 62.897 pesanan berhasil dibersihkan dengan penegakan zero leakage pada fitur terjadwal.

### 2. Keandalan Risk Prioritization Ranking

Average Precision 0,7364 (+16% lift vs baseline) membuktikan model efektif menyusun antrean pesanan darurat.

### 3. Nilai Tambah Topologi Graf Bipartit

Graph analytics mengidentifikasi konsentrasi keterlambatan tinggi pada kategori hub utama (17, 18, 24).

## ACTIONABLE RECOMMENDATIONS

- Cluster Deployment: Migrasi kode PySpark distributed-ready ke multi-node cluster YARN / Kubernetes.
- Top-K Dashboard Alert: Integrasi skor risiko ke antarmuka harian staf gudang untuk mitigasi penalti SLA.
- Handling Unseen Categories: Pengembangan representasi kategori dinamis untuk mengatasi category drift.

## TERIMA KASIH

Rafael Yudianto | NIM: 2702752495
Magister Teknik Informatika – BINUS Graduate Program